Лабораторная 2. Отчёт

Источник: Books to Scrape. Собраны 40 книг с двух страниц каталога через BeautifulSoup и Octoparse. Минимум программной части по заданию - 20 записей. Две страницы нужны для демонстрации пагинации.

Цель - получить таблицу из HTML, очистить поля и сравнить программный и визуальный сбор. Пошаговый просмотр сохранённых результатов находится в lab2.ipynb.

BeautifulSoup

scraper.py получает HTML через requests, разбирает карточки и открывает страницы книг для получения категории и UPC.

Поле	Правило поиска	Тип в программе
`title`	Атрибут `title` у `h3 a` внутри `article.product_pod`	`str`
`category`	Предпоследний элемент `ul.breadcrumb li` на странице книги	`str`
`price_gbp`	Число из `p.price_color` без знака валюты	`float`
`rating`	Класс `One`…`Five` у `p.star-rating`, преобразованный в 1…5	`int`
`url`	`href` у `h3 a`, преобразованный в абсолютную ссылку через `urljoin`	`str`
`upc`	Строка `UPC` в `table.table.table-striped` на странице книги	`str`

UPC хранится как строка, чтобы не потерять начальные нули. Пробелы и переводы строк очищаются. Дубли удаляются по UPC, а если его нет - по URL. Следующая страница находится по `li.next a`. Лимит относится к уникальным книгам.

Тайм-аут запроса - 10 секунд. При временных сетевых ошибках и HTTP 429/500/502/503/504 запрос повторяется до двух раз с паузами 0,5 и 1 секунда. HTTP 404 не повторяется.

Команды запуска приведены в README. Результат: books.csv, 40 строк, 6 полей, без дублей и пропусков.

Первые пять книг:

Название	Категория	Цена, GBP	Рейтинг	UPC
A Light in the Attic	Poetry	51.77	3	a897fe39b1053632
Tipping the Velvet	Historical Fiction	53.74	1	90fa61229261140a
Soumission	Fiction	50.10	1	6957f44c3847a760
Sharp Objects	Mystery	47.82	4	e00eb4fd7b871a48
Sapiens: A Brief History of Humankind	History	54.23	5	4165285e1663650f

Таблица BeautifulSoup

Books to Scrape — результат

Строк: 40 | Полей: 6 | Доля пропусков: 0,00 %

title	category	price_gbp	rating	url	upc
A Light in the Attic	Poetry	51.77	3	https://books.toscrape.com/catalogue/a-light-in-the-attic_1000/index.html	a897fe39b1053632
Tipping the Velvet	Historical Fiction	53.74	1	https://books.toscrape.com/catalogue/tipping-the-velvet_999/index.html	90fa61229261140a
Soumission	Fiction	50.1	1	https://books.toscrape.com/catalogue/soumission_998/index.html	6957f44c3847a760
Sharp Objects	Mystery	47.82	4	https://books.toscrape.com/catalogue/sharp-objects_997/index.html	e00eb4fd7b871a48
Sapiens: A Brief History of Humankind	History	54.23	5	https://books.toscrape.com/catalogue/sapiens-a-brief-history-of-humankind_996/index.html	4165285e1663650f
The Requiem Red	Young Adult	22.65	1	https://books.toscrape.com/catalogue/the-requiem-red_995/index.html	ff7dbf2323deb740
The Dirty Little Secrets of Getting Your Drea…	Business	33.34	4	https://books.toscrape.com/catalogue/the-dirty-little-secrets-of-getting-your-dream-job_994/index.html	2597b5a345f45e1b
The Coming Woman: A Novel Based on the…	Default	17.93	3	https://books.toscrape.com/catalogue/the-coming-woman-a-novel-based-on-the-life-of-the-infamous-fem…	e72a5dfc7e9267b2
The Boys in the Boat: Nine Americans and …	Default	22.6	4	https://books.toscrape.com/catalogue/the-boys-in-the-boat-nine-americans-and-their-epic-quest-for-gold…	e10e1e165dc8be4a
The Black Maria	Poetry	52.15	1	https://books.toscrape.com/catalogue/the-black-maria_991/index.html	1dfe412b8ac00530
Starving Hearts (Triangular Trade Trilogy, #1)	Default	13.99	2	https://books.toscrape.com/catalogue/starving-hearts-triangular-trade-trilogy-1_990/index.html	0312262ecafa5a40
Shakespeare's Sonnets	Poetry	20.66	4	https://books.toscrape.com/catalogue/shakespeares-sonnets_989/index.html	30a7f60cd76ca58c
Set Me Free	Young Adult	17.46	5	https://books.toscrape.com/catalogue/set-me-free_988/index.html	ce6396b0f23f6ecc
Scott Pilgrim's Precious Little Life (Scott Pil…	Sequential Art	52.29	5	https://books.toscrape.com/catalogue/scott-pilgrims-precious-little-life-scott-pilgrim-1_987/index.html	3b1c02bac2a429e6
Rip it Up and Start Again	Music	35.02	5	https://books.toscrape.com/catalogue/rip-it-up-and-start-again_986/index.html	a34ba96d4081e6a4
Our Band Could Be Your Life: Scenes from …	Music	57.25	3	https://books.toscrape.com/catalogue/our-band-could-be-your-life-scenes-from-the-american-indie-unde…	deda3e61b9514b83
Olio	Poetry	23.88	1	https://books.toscrape.com/catalogue/olio_984/index.html	feb7cc7701ecf901
Mesaerion: The Best Science Fiction Storie…	Science Fiction	37.59	1	https://books.toscrape.com/catalogue/mesaerion-the-best-science-fiction-stories-1800-1849_983/index.…	e30f54cea6b38190
Libertarianism for Beginners	Politics	51.33	2	https://books.toscrape.com/catalogue/libertarianism-for-beginners_982/index.html	a18a4f574854aced
It's Only the Himalayas	Travel	45.17	2	https://books.toscrape.com/catalogue/its-only-the-himalayas_981/index.html	a22124811bfa8350
In Her Wake	Thriller	12.84	1	https://books.toscrape.com/catalogue/in-her-wake_980/index.html	23356462d1320d61
How Music Works	Music	37.32	2	https://books.toscrape.com/catalogue/how-music-works_979/index.html	327f68a59745c102
Foolproof Preserving: A Guide to Small Batc…	Food and Drink	30.52	3	https://books.toscrape.com/catalogue/foolproof-preserving-a-guide-to-small-batch-jams-jellies-pickles-co…	5674a18a29a43ced
Chase Me (Paris Nights #2)	Romance	25.27	5	https://books.toscrape.com/catalogue/chase-me-paris-nights-2_977/index.html	c2e46a2ee3b4a322
Black Dust	Romance	34.53	5	https://books.toscrape.com/catalogue/black-dust_976/index.html	00bfed9e18bb36f3
Birdsong: A Story in Pictures	Childrens	54.64	3	https://books.toscrape.com/catalogue/birdsong-a-story-in-pictures_975/index.html	952fd0094825bf5f
America's Cradle of Quarterbacks: Western …	Default	22.5	3	https://books.toscrape.com/catalogue/americas-cradle-of-quarterbacks-western-pennsylvanias-football-f…	c7d160c2c0de586f
Aladdin and His Wonderful Lamp	Default	53.13	3	https://books.toscrape.com/catalogue/aladdin-and-his-wonderful-lamp_973/index.html	904208d6aa64b655
Worlds Elsewhere: Journeys Around Shake…	Nonfiction	40.3	5	https://books.toscrape.com/catalogue/worlds-elsewhere-journeys-around-shakespeares-globe_972/inde…	4c28def39d850cdf
Wall and Piece	Art	44.18	4	https://books.toscrape.com/catalogue/wall-and-piece_971/index.html	ccd9ffa25efabdea
The Four Agreements: A Practical Guide to …	Spirituality	17.66	5	https://books.toscrape.com/catalogue/the-four-agreements-a-practical-guide-to-personal-freedom_970/i…	6258a1f6a6dcfe50
The Five Love Languages: How to Express …	Nonfiction	31.05	3	https://books.toscrape.com/catalogue/the-five-love-languages-how-to-express-heartfelt-commitment-to-y…	3c0339852294 53bf
The Elephant Tree	Thriller	23.82	5	https://books.toscrape.com/catalogue/the-elephant-tree_968/index.html	5dada2b7be26bd03
The Bear and the Piano	Childrens	36.89	1	https://books.toscrape.com/catalogue/the-bear-and-the-piano_967/index.html	9f6568e9c95f80b0
Sophie's World	Philosophy	15.94	5	https://books.toscrape.com/catalogue/sophies-world_966/index.html	6be3beb0793a53e7
Penny Maybe	Default	33.29	3	https://books.toscrape.com/catalogue/penny-maybe_965/index.html	668fe56b17cfcd4f
Maude (1883-1993):She Grew Up with the …	Default	18.02	2	https://books.toscrape.com/catalogue/maude-1883-1993she-grew-up-with-the-country_964/index.html	094b265567e1c300
In a Dark, Dark Wood	Mystery	19.63	1	https://books.toscrape.com/catalogue/in-a-dark-dark-wood_963/index.html	19ed25f641d5efd
Behind Closed Doors	Thriller	52.22	4	https://books.toscrape.com/catalogue/behind-closed-doors_962/index.html	be5cc846f45496fb
You can't bury them all: Poems	Poetry	33.63	2	https://books.toscrape.com/catalogue/you-cant-bury-them-all-poems_961/index.html	55f9da0c5eea2e10

Octoparse

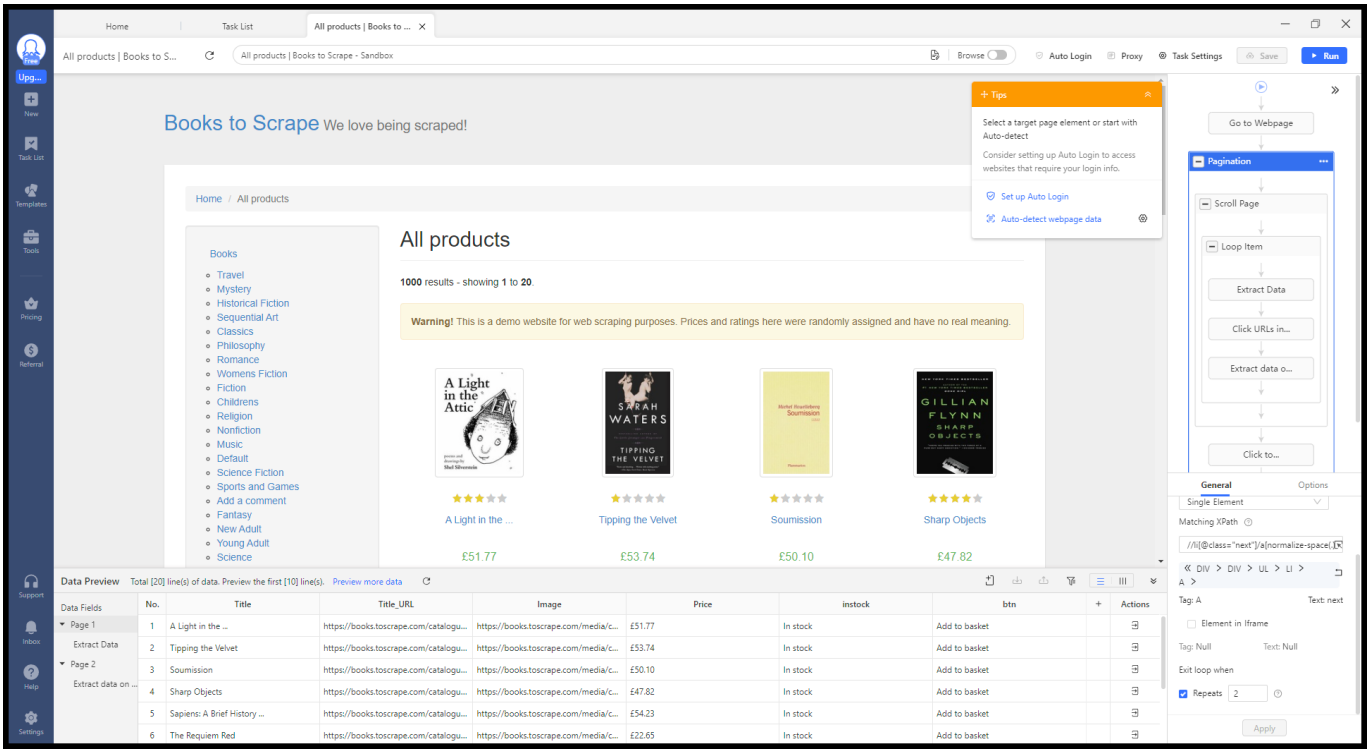
Использована задача `All products | Books to Scrape - Sandbox` в Octoparse 10.1.1.

Настройка

1. `Go to Webpage` открывает первую страницу каталога.
2. `Loop Item` обходит карточки книг.
3. `Extract Data` получает цену и ссылку из карточки.
4. `Click URLs in the list` открывает страницу книги по `/article[1]/h3[1]/a[1]`.
5. `Extract data on the detail page` получает полное название, UPC и HTML рейтинга.
6. `Click to Paginate` нажимает next по XPath `//li[@class="next"]/a[normalize-space(.)="next"]`.

В `Pagination` установлено `Repeats = 2`: две страницы по 20 книг.

Настройка Octoparse



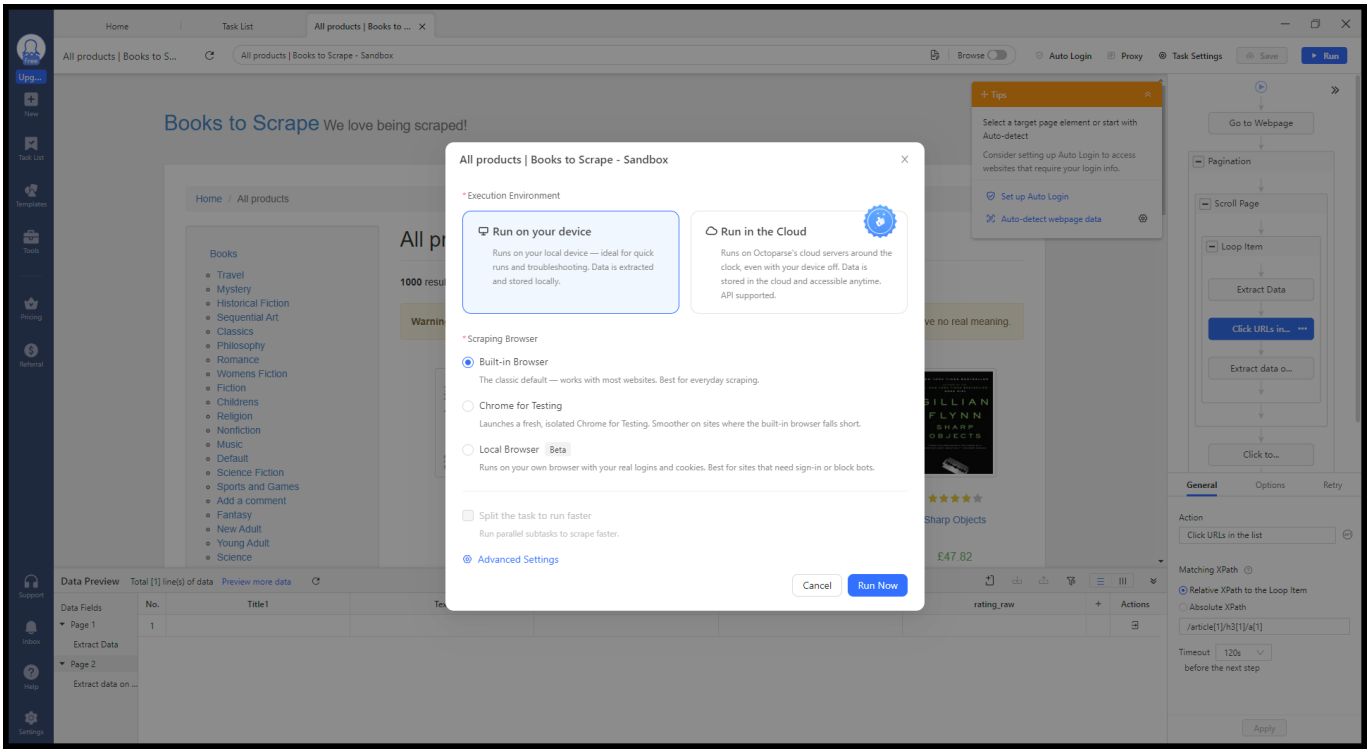
Итоговое поле	Поле Octoparse	Содержимое
`title`	`Title1`	Полное название из `h1` на странице книги
`price_gbp`	`Price`	Цена из карточки
`rating`	`rating_raw`	HTML элемента `p.star-rating` с классом `One…Five`
`url`	`Title_URL`	Ссылка на книгу
`upc`	`upc`	UPC из первой строки таблицы сведений о книге

`Title` содержит сокращённые названия у 22 книг, поэтому использовано `Title1`. Поле категории заполнено только для пяти книг из Poetry и исключено из итогового CSV.

Запуск и экспорт

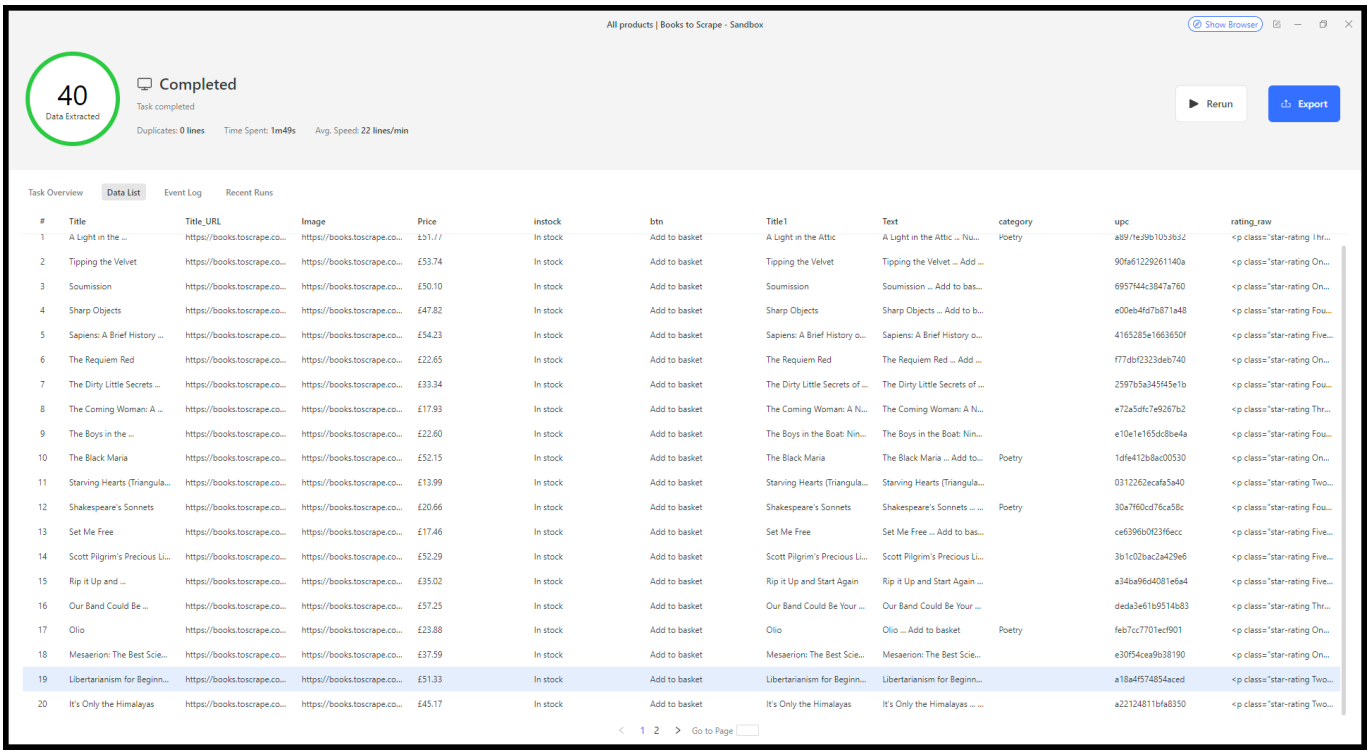
Выбраны `Run on your device` и `Built-in Browser`, затем `Run Now`.

Параметры запуска



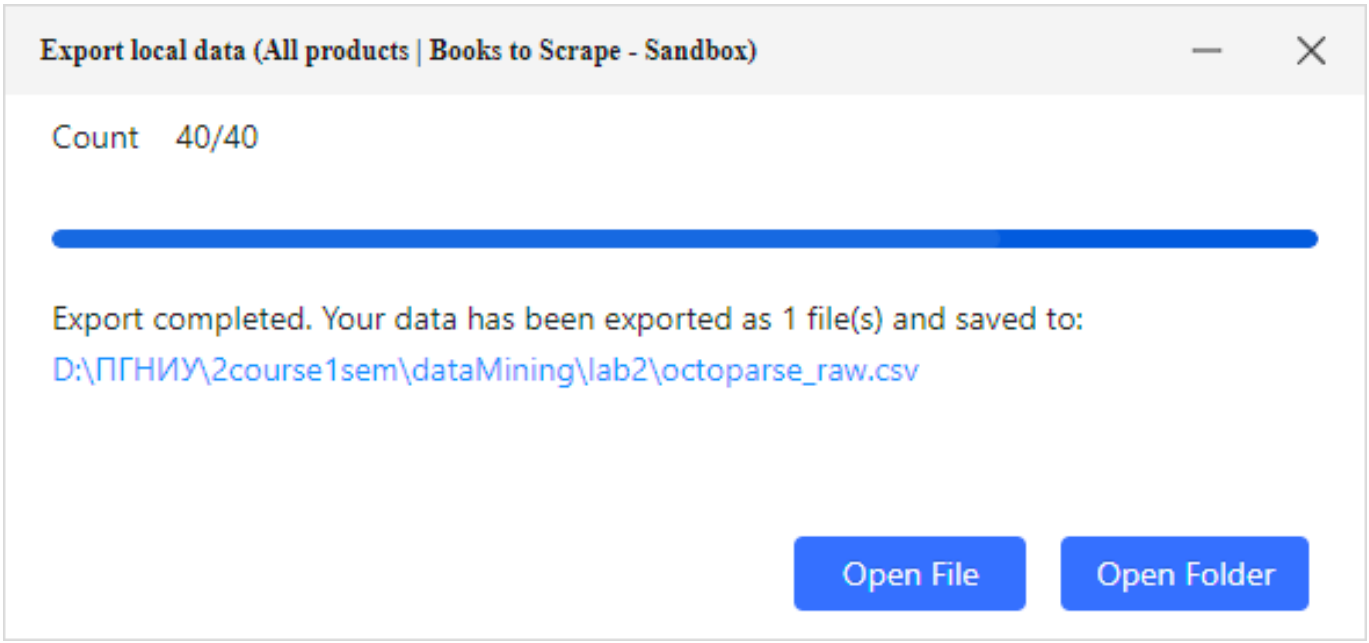
Задача завершилась со статусом Completed: 40 строк за 1 минуту 49 секунд, дублей нет.

Результат запуска



Через `Export → CSV → Confirm` сохранён octoparse_raw.csv: 40 строк, 11 исходных полей.

Экспорт CSV



normalize_octoparse.py выбирает пять полей, очищает пробелы, преобразует цену в float и рейтинг в число от 1 до 5. Дубли удаляются по UPC. Пустые обязательные поля, неверные числа и противоречивые дубли вызывают ошибку.

Очищенный результат - octoparse_books.csv: 40 строк, 5 полей, без дублей и пропусков.

Сравнение

compare_results.py сравнивает таблицы по UPC.

Показатель	BeautifulSoup	Octoparse после очистки
Страниц каталога	2	2
Строк	40	40
Уникальных UPC	40	40
Полей	6	5
Доля пропусков	0,00 %	0,00 %

У всех 40 книг совпадают `title`, `price_gbp`, `rating`, `url` и `upc`. В таблице BeautifulSoup дополнительно сохранена категория.