Лабораторная 3. Сбор данных через REST API

1. Цель и вариант

Вариант 3: Open Library Search и Open Library Authors. Задача - получить книги по теме, добавить сведения об авторах и проанализировать годы издания, языки и полноту данных. В сохранённом наборе по запросу `python programming` находятся 360 книг. Все приведённые ниже показатели относятся к этому набору; новый запуск может найти дополнительные ключи. Минимум задания - 300 записей и три страницы. В n8n сохранены 30 книг при минимуме 20.

2. Паспорт API

Параметр	Значение
Название и базовый URL	Open Library, https://openlibrary.org
Эндпоинты	`/search.json` - поиск книг; `/authors/ID.json` - сведения об авторе
Версия	В URL не указана
Метод и формат	GET, ответ JSON
Авторизация	Публичные запросы, API-ключ не требуется
Параметры поиска	q, offset, limit, fields, sort; в работе sort=key
Пагинация	offset - смещение, limit - размер порции
Документированный лимит	Без контакта в User-Agent - 1 запрос/с, то есть 60 запросов/мин
Заголовки	User-Agent и Accept в запросе; проверка Content-Type в ответе; Retry-After учитывается при наличии
Заголовки лимитов	RateLimit-* и X-RateLimit-* сохраняются, если пришли; в примере их нет
Время	Год издания - число; время сбора и изменения автора приводится к datetime в UTC
Ключи	key книги (`work_id`) и ключ автора (`author_key`)
Персональные сведения	Имена авторов; контакты, адреса и биографии в файлы не сохраняются
Условия использования	Небольшая учебная выборка, паузы и кэш. Для массового каталога Open Library рекомендует выгрузки данных

3. Архитектура сбора

Источник → сбор → нормализация → проверка → хранение. Search API и Authors API → GET-запросы через requests.Session → таблица книг, отдельная таблица языков и присоединение авторов → проверки полноты, ключей и значений → JSONL, CSV, журнал и состояние. Код находится в collect.py. Исходные записи книг сохраняются в data_raw.jsonl, итоговая таблица - в data_clean.csv. Сведения Authors API кэшируются в authors_cache.json.

4. Пагинация, лимиты и повторы

Python получает четыре порции по 90 книг: offset 0, 90, 180, 270. Функция paginate принимает page_size, max_records и max_pages. Смещение увеличивается на фактическое число записей. Остановка - пустая порция, достижение общего числа найденных книг, лимит 360 записей или 20 страниц.

Между запросами выдерживается 1,1 секунды; timeout - 20 секунд. User-Agent обозначает программу, Accept=application/json задаёт ожидаемый формат. Проверяются HTTP-статус, Content-Type и структура JSON. Ошибка содержит первые 200 байт тела ответа.

Повторяются только HTTP 429 и 5xx, не более двух раз после первой попытки. Задержка растёт, добавляется случайная часть; Retry-After задаёт нижнюю границу ожидания. Остальные 4xx и сетевые ошибки записываются в журнал и прерывают сбор.

collection_log.csv содержит страницу, URL, параметры, статус, число записей, длительность и время запроса. headers_example.json содержит настоящий ответ HTTP 200 с Content-Type application/json; команда `python collect.py --show-headers` обновляет этот пример одним запросом.

5. Проверка качества и анализ данных

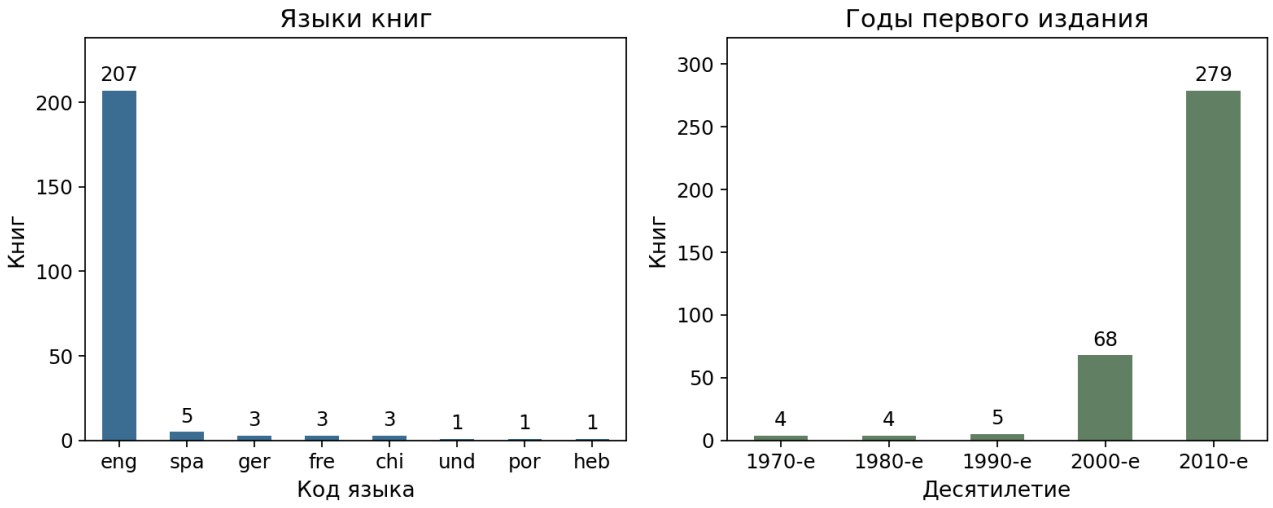
JSON преобразован через pandas.json_normalize с sep. Массив language развёрнут через record_path и meta: получены 225 связей в book_languages.csv. Для каждого произведения используются сведения первого автора. Общее число авторов сохранено отдельно. Объединение по author_key выполнено с проверкой many_to_one: до и после него 360 книг, сведения автора найдены для 357. Числа приведены к numeric, временные поля - к datetime с UTC.

Поле	Полнота, %
work_id	100.00
title	100.00
first_publish_year	100.00
edition_count	100.00
author_key	99.17
author_name_catalogue	99.17
author_count	100.00
language_count	100.00
languages	60.00
collected_at	100.00
url	100.00
author_name_verified	99.17
author_revision	99.17
author_modified_at	99.17
author_url	99.17
author_matched	100.00

Уникальных ключей - 360; дублей и пустых обязательных полей - 0. Проверены положительное число изданий, год не позже текущего, формат work_id и непустое название. Нарушений нет. Результаты сохранены в quality.json и completeness.csv. Целые поля имеют nullable-тип Int64, collected_at и author_modified_at - datetime с UTC.

По правилу 1,5 IQR отмечены 11 необычных лет издания и 50 значений числа изданий. Границы: 1998-2030 и −0,5-3,5 соответственно. Это статистические кандидаты на проверку, а не ошибки: старые книги и несколько изданий допустимы. Строки не удалялись; результат - outliers.json. Годы первого издания: от 1975 до 2019; медиана - 2013, среднее - 2012,49. В 2010-е впервые опубликованы 279 из 360 книг. Языки указаны у 216 книг; английский есть у 207. Это первые 360 результатов, отсортированных по ключу, поэтому выводы относятся только к этой выборке.

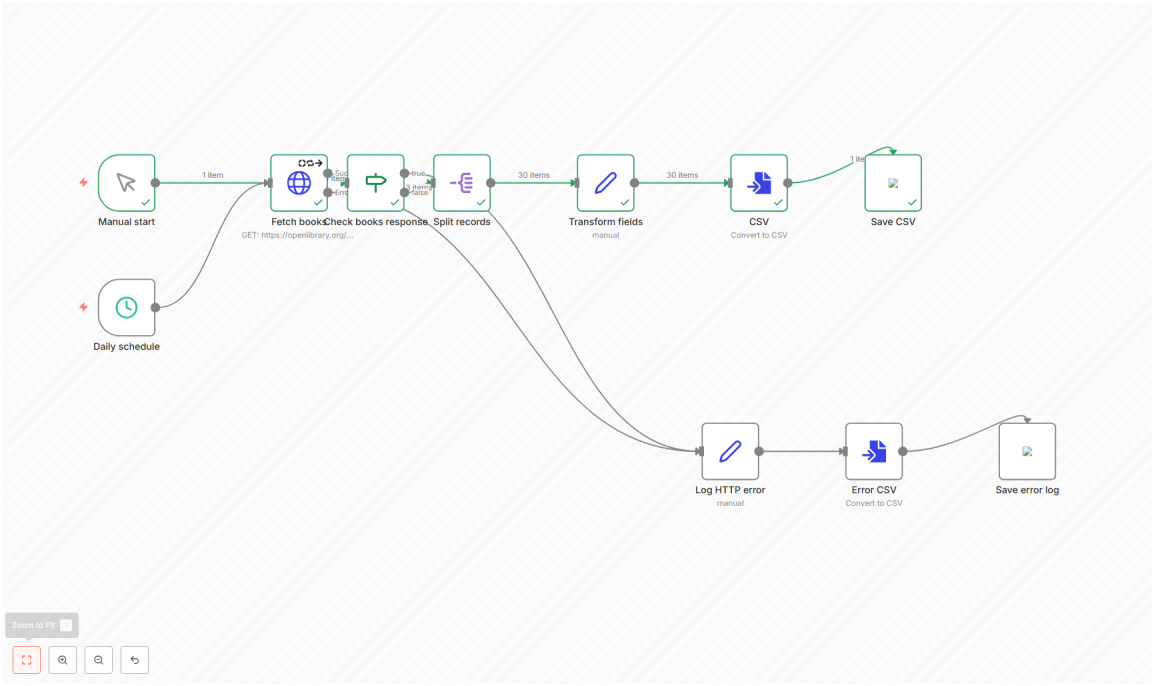
Языки книг и годы первого издания



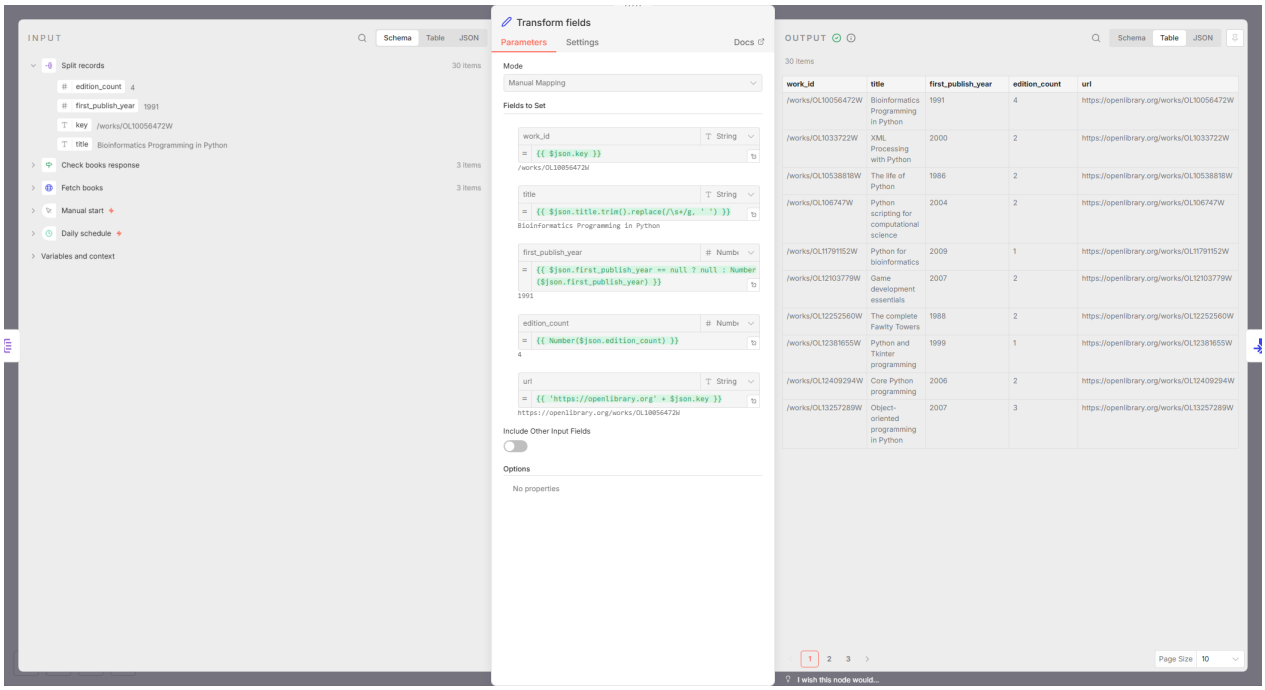
6. No-code сценарий в n8n

Manual start или Daily schedule → Fetch books → Check books response → Split records → Transform fields → CSV → Save CSV. Расписание настроено на ежедневный запуск. Fetch books получает три порции по 10 книг: offset 0, 10, 20. Между запросами пауза 1,1 секунды, timeout - 25 секунд. Transform fields переименовывает key в work_id, очищает название, приводит год и число изданий к числам и строит URL. Настроены повторы сетевого узла и отдельная ветка Log HTTP error → Error CSV → Save error log. В сохранённой проверке эта ветка сформировала журнал ошибки. В workflow.json сохранены настройки сценария. Получены 30 книг в nocode_result.csv. Все пять общих полей совпадают с Python: work_id, title, first_publish_year, edition_count, url. Запросов к Authors API в n8n нет: это упрощённый сценарий.

Схема n8n



Успешный результат n8n



7. Сравнение подходов и вывод

Показатель	Python	n8n
Разработка до первой выгрузки, мин	5.88	0.65
Число записей	360	30
Время первого прогона, с	348.81	13.34
HTTP-запросы	310	3
Тела ответов, КБ (1000 байт)	180.55	3.88
Пагинация	Функция с лимитами	HTTP Request, три порции
Обработка ошибок	Проверки, повторы, журнал	Повторы, проверка ответа, ветка ошибки
Повторный запуск	Только новые ключи	Повторная запись CSV
Воспроизводимость	Код, notebook, Git	Экспорт JSON, Git
Плата сервисам при 100 запусках, руб.	0	0
Порог входа, 1-5, субъективно	4	2

Замер подготовки включает получение первой выгрузки, но не предварительное планирование и установку окружения. Поэтому он не равен полному времени разработки. Для сборов использованы готовые учебные шаблоны. Основание цифр - development_metrics.json, metrics_initial.json и nocode/metrics.json. Python собирает больше книг и добавляет авторов, поэтому полное время нельзя сравнивать напрямую. Повтор Python занял 8,67 секунды и сделал четыре запроса. Платных API и облачного n8n нет; стоимость электричества, оборудования и сопровождения не оценивалась. state.json хранит известные ключи и watermark - смещение и последний ключ завершённого сбора. Повторный запуск снова проверяет четыре порции и добавляет только новые ключи. В сохранённом повторе новых записей 0, CSV не изменился. Кэш позволил не повторять запросы к 306 авторам.

Python выбран для полной таблицы, анализа и повторного сбора. n8n удобен для небольшой выгрузки по расписанию. В совместном варианте Python собирает и проверяет данные, n8n запускает его по расписанию и сообщает об ошибках.

8. Правовая и этическая оценка

Open Library публикует каталог и использует CC0 для вкладов в него; при этом возможные права на отдельные материалы нужно учитывать. Собираются метаданные, а не тексты книг. Использован API без обхода защиты, с паузами и кэшем. При увеличении объёма следует использовать выгрузки каталога и указать контакт в User-Agent. Имена авторов могут быть персональными данными. В рамках учебного исследования рассматривается п. 8 ч. 1 ст. 6 152-ФЗ: обработка для научной деятельности допустима при соблюдении прав и законных интересов человека. Сам по себе открытый API не даёт разрешения на любое использование и распространение сведений. Контакты и биографии в файлы не сохранялись. Сырые ответы и кэш хранятся локально до проверки работы. Предлагаемый срок удаления - не позднее 30 дней после проверки. Для публичных аналитических выводов достаточно агрегатов по годам и языкам.

9. Источники

- Open Library Search API, Authors API.

- Правила и лимиты Open Library, использование данных, оговорка о правах.

- HTTP Request и пагинация n8n.

- 152-ФЗ, статья 6.