# Лабораторная 5. Краулинг Scrapy и n8n

Вариант 3. С Quotes to Scrape собраны 100 цитат с десяти страниц. Для объёма от 300 записей добавлен паук Books to Scrape. В SQLite сохранены 100 цитат и 304 книги, всего 404 записи. Задание требует не менее 300 записей, 10 страниц списка и двух уровней обхода. В no-code части нужно не менее 30 записей; в n8n сохранены 30 цитат.

## Источники и пауки

Проект создан через `scrapy startproject`. Схема записи - items.py, пауки - spiders, обработка - pipelines.py.

Паук Quotes обходит список и страницы авторов. На первом уровне получает текст, автора и теги, на втором - биографию, место и дату рождения. Паук Books обходит каталог и страницы книг: название, рейтинг, UPC, цену без налога, наличие, отзывы, категорию и описание.

Используется обычный Spider: для двух уровней с разными полями проще задать отдельные callback. Данные первого уровня передаются через `cb_kwargs`, пагинация - через `response.follow`. Scheduler управляет очередью и повторными URL, Downloader - HTTP-запросами, Pipeline - очисткой и записью в базу. Сетевые ошибки учитываются через errback.

## Обработка и настройки

| Звено | Действие |
|---|---|
| 100 - валидация | Проверяет обязательные поля, DropItem и счётчик причины |
| 200 - очистка | Пробелы, цена float, количество int, дата ISO, регистр тегов и UPC |
| 300 - дедупликация | Книга по UPC, цитата по автору и тексту; состояние сохраняется для JOBDIR |
| 400 - SQLite | Соединение открывается один раз, executemany пакетами по 50, INSERT OR REPLACE |

Валидация и очистка считают отброшенные записи по причине: пустые поля, неверные значения и повторный ключ. Ключ книги - UPC, ключ цитаты - автор и текст. Счётчики: dropped/missing_fields, dropped/invalid_value, dropped/duplicate и database/written. Item задан в items.py и используется обоими пауками. SQLite записывает данные пакетами по 50 через `executemany` и `INSERT OR REPLACE`.

| Настройка | Значение и причина |
|---|---|
| ROBOTSTXT_OBEY | True - запросы учитывают robots.txt |
| USER_AGENT | Учебное назначение |
| CONCURRENT_REQUESTS / PER_DOMAIN | 2 / 2 - ограничение одновременных запросов |
| DOWNLOAD_DELAY | 0,25 с с вариацией - пауза между запросами |
| AutoThrottle | Включён, target=1, задержка 0,3-3 с |
| DOWNLOAD_TIMEOUT | 25 с |
| RETRY_TIMES / CODES | 2; 429, 500, 502, 503, 504 |
| DEPTH_LIMIT | 25 - хватает для пагинации и страниц авторов, ограничивает глубину |
| CLOSESPIDER_ITEMCOUNT | 300 - остановка после достижения нужного объёма |
| CLOSESPIDER_PAGECOUNT / TIMEOUT | 500 / 900 с |
| HTTPCACHE | Включён для отладки, срок 86400 с |
| LOG_LEVEL | INFO |

Два параллельных запроса и задержка ограничивают нагрузку. AutoThrottle меняет задержку по времени ответа. Лимиты записей, страниц и времени останавливают затянувшийся обход. HTTP-кэш используется при повторных запусках. Короткие пояснения обязательных настроек добавлены в settings.py.

## Остановка, продолжение и кэш

| Прогон | Записей | Время, с | Cache store | Cache hit | Dupefilter |
|---|---|---|---|---|---|
| resume_1 | 35 | 20.078 | 58 | 25 | 0 |
| resume_2 | 65 | 18.516 | 56 | 73 | 1 |
| cache_1 | 100 | 36.781 | 114 | 97 | 0 |
| cache_2 | 100 | 2.750 | 0 | 211 | 0 |
| books_full | 304 | 10.906 | 0 | 326 | 0 |

Первый запуск Quotes остановлен на 35 записях, второй в том же JOBDIR добавил ещё 65. Получены 100 уникальных цитат. Dupefilter во втором запуске отклонил один повторный запрос. В jobstate сохранены очередь, обработанные URL и ключи записей.

Два запуска с отдельным кэшем получили одинаковые 100 цитат. Во втором было 211 попаданий в кэш и не было новых сетевых загрузок. Статистика - в data.

Books использовал заполненный кэш. При лимите 300 сохранились 304 книги: после начала закрытия завершились уже запущенные запросы. Обработано 20 страниц каталога.

## Качество данных

| Таблица | Строк | Уникальных ключей | Дублей | Пустых обязательных |
|---|---|---|---|---|
| quotes | 100 | 100 | 0 | 0 |
| books | 304 | 304 | 0 | 0 |

Полнота каждого поля - 100 %, подробности в completeness.csv. При сборе Books отброшена одна запись с пустым обязательным полем. Ошибок в цене, рейтинге, наличии и числе отзывов нет. Числовая статистика обработанных ответов (включая HTTP-кэш):

| Прогон | Коды ответов и количество | Повторы | Брак |
|---|---|---|---|
| Quotes cache_1 | 200: 110; 308: 100; 404: 1 | 0 | 0 |
| Quotes cache_2 | 200: 110; 308: 100; 404: 1 | 0 | 0 |
| Books books_full | 200: 325; 404: 1 | 0 | 1, обязательное поле |

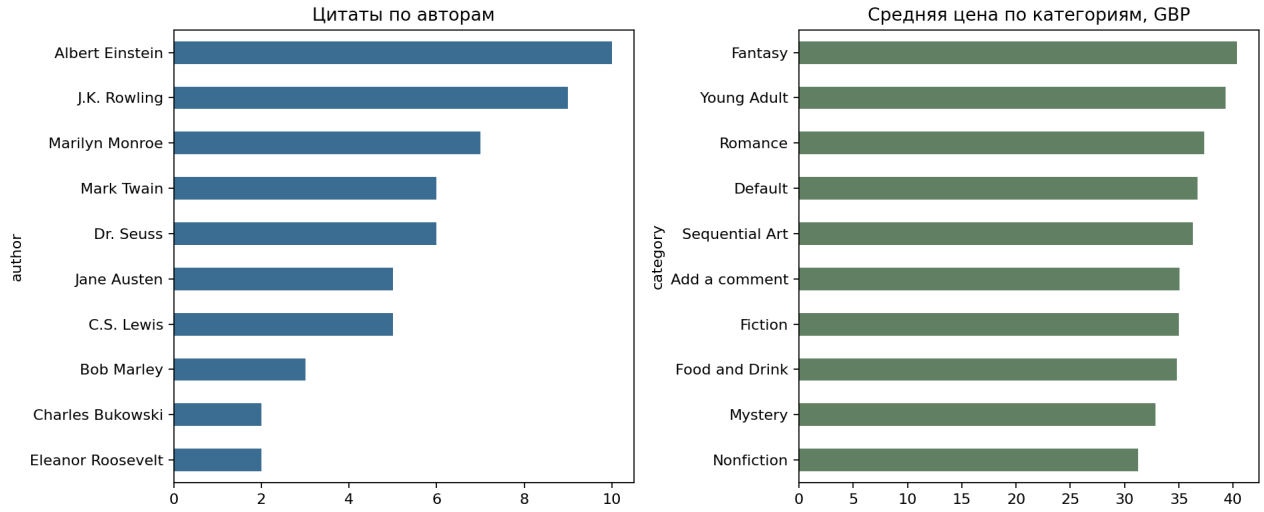
Коды из Scrapy включают воспроизведённые кэшированные ответы и перенаправления, поэтому их сумма не равна числу новых сетевых запросов. robots.txt с 404 не означает потерю карточки. Время, байты и сетевые запросы отдельно показаны в таблицах кэша и сравнения; полная статистика - quality/current.json.

Пример агрегатов:

| Категория | Книг | Средняя цена, GBP |
|---|---|---|
| Default | 52 | 36.74 |
| Nonfiction | 33 | 31.27 |
| Fiction | 23 | 34.97 |
| Sequential Art | 21 | 36.30 |
| Add a comment | 20 | 35.04 |

В quality_report.ipynb посчитаны цитаты по авторам и тегам, средние цены по категориям, коды ответов, повторы и трафик.

Цитаты по авторам и цены книг



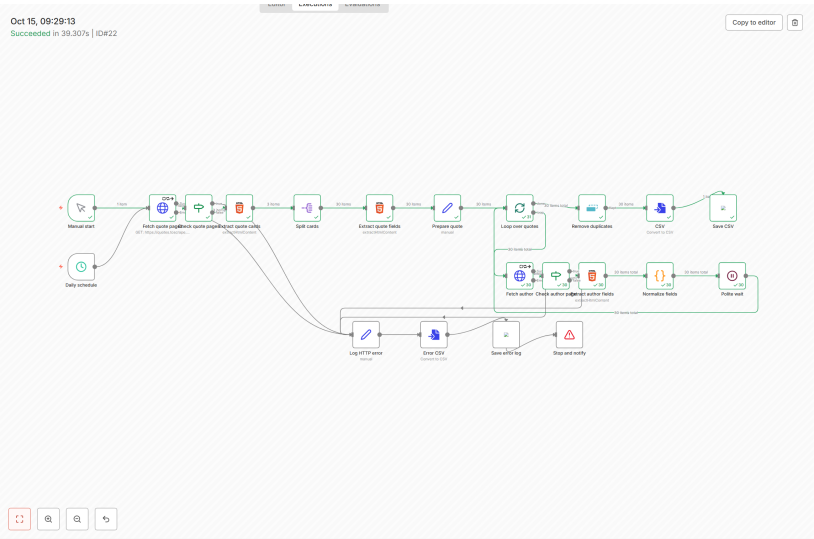

smoke_check.py сравнивает два запуска. Предупреждение появляется, если число записей упало больше чем на 20 % или доля строк с пустыми обязательными полями превысила 5 %. Для сохранённой базы предупреждений нет. Подготовленные случаи 404 → 300 строк и 6% обязательных пропусков дают код 1; неизменившийся набор - код 0. Это учебная проверка функции, не результат нового сбора; quality/smoke_demonstration.json.

## n8n

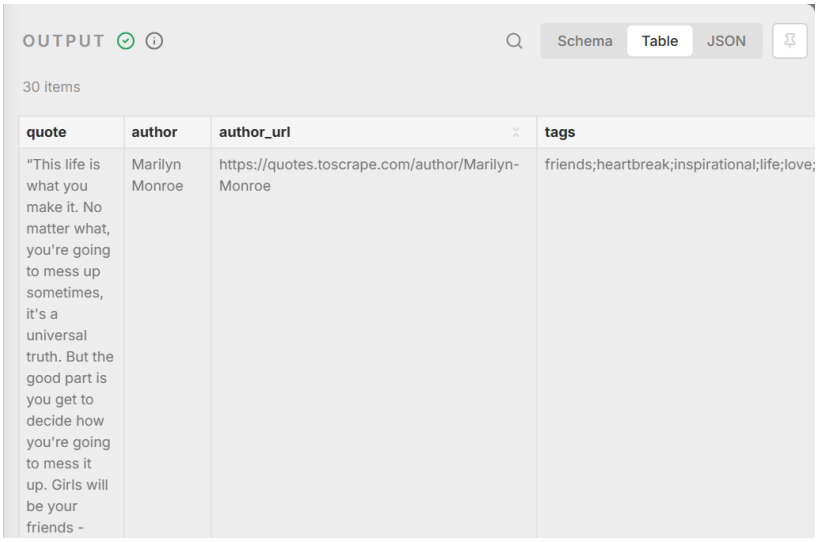
Workflow получает три страницы цитат, разбирает карточки, по очереди открывает страницы авторов, очищает поля и сохраняет CSV. Между запросами есть пауза. В HTTP-узлах включены повторы, неверные ответы и ошибки записываются отдельно. После Save error log добавлен Stop and notify: ошибка видна в интерфейсе n8n, запись остаётся в CSV. Ежедневное расписание настроено. Повторная проверка дала 30 строк; подготовленный HTTP 404 прошёл через журнал и завершил workflow ошибкой. Подтверждение - metrics_verification.json и metrics_error_demo.json в nocode. Retry On Fail здесь общий для ошибок HTTP-узла: учебный 404 вызвал три обращения. В этой работе это ограничение сценария; политика отдельных кодов реализована в седьмой.

Получены 30 цитат в nocode_result.csv. Текст, автор, биография, место и дата рождения совпадают с SQLite.

Workflow n8n



Результат n8n




## Сравнение

Для Scrapy взят полный запуск Quotes с изначально пустым кэшем.

| Показатель | Scrapy | n8n |
|---|---|---|
| Подготовка до первой выгрузки, мин | 0.40 | 17.64 |
| Цитат | 100 | 30 |
| Время, с | 36.78 | 38.64 |
| Записей в минуту | 163.1 | 46.6 |
| Сетевых запросов | 114 | 59 |
| Тел ответов, МиБ | 0.107 | 0.143 |
| Дедупликация запросов | Scheduler; авторы дополнительно через кэш | По записям после обхода |
| Возобновление | JOBDIR | Повторный запуск небольшого workflow |
| Расписание и ошибки | Внешний запуск и журналы | Узлы расписания и ветка ошибки |
| Версионирование | Git | Экспорт JSON и Git |
| Усилия поддержки, субъективно 1-5 | 4 | 3 |

Время подготовки измерено до первой выгрузки, без установки окружения. Scrapy получил 100 цитат, n8n - 30, поэтому также сравнивается число записей в минуту.

Для разового обхода 500 страниц выбран Scrapy: уже есть очередь, пагинация и база. Для 40 000 страниц ежедневно также нужен Scrapy с состоянием и контролем нагрузки. Для небольшого сбора с отправкой отчёта подходит n8n. В совместной схеме n8n может запускать Scrapy и отправлять сводку из базы.

## Устойчивость и условия использования

Если изменятся классы `.quote`, `.author-description` или подписи таблицы, поля могут пропасть. Такие изменения видны по полноте, счётчикам DropItem и smoke-check. После изменения страницы нужно проверить селекторы на нескольких записях.

Сайты учебные, правила robots.txt учитываются, частота запросов ограничена. Имена и биографии авторов могут относиться к персональным данным; контакты не собирались. В правовой оценке учтён п. 8 ч. 1 ст. 6 152-ФЗ: научная деятельность допускается при соблюдении прав и законных интересов человека. Публичная страница не разрешает любое дальнейшее использование биографии. Исходные биографии предлагается удалить не позднее чем через 30 дней после проверки.

Источники: Quotes to Scrape, Books to Scrape, Scrapy JOBDIR, AutoThrottle, n8n HTML.