Лабораторная работа 5 Промышленный краулинг Scrapy и n8n

ПМИ-2-2025. Вариант 3.

1. Цель и вариант

Разработать Scrapy-проект с обходом «список цитат → страница автора», четырьмя звеньями Item Pipeline, SQLite, возобновлением и HTTP-кэшем; сравнить его с n8n на одинаковых 30 цитатах. В Excel назначен вариант 3: *quotes.toscrape.com*.

Получены все 100 уникальных цитат с десяти страниц и сведения 50 авторов. Дополнительно выполнен обход тегов по подходу LaintAge/web-scrapers: сохранены 190 связей «цитата-тег». Они относятся к 69 цитатам и не являются 190 новыми цитатами. Общий минимум ТЗ в 300 уникальных записей цитат на этом каталоге не достигнут: источник содержит 100; страница 11 пуста. Значение *CLOSESPIDER_ITEMCOUNT=300* задаёт предел, а не гарантирует объём.

2. Карта источника и ключи

Основная точка входа - *https://quotes.toscrape.com/*; список содержит *.quote*, текст *span.text*, имя *small.author*, теги *.tags a.tag*, ссылку на автора и *li.next a*. На втором уровне извлекаются *.author-born-date*, *.author-born-location*, *.author-description*. Ссылки приводятся к URL с завершающей /, чтобы не создавать лишних HTTP 308.

Дополнительный путь: десять популярных тегов главной → страницы тегов с пагинацией → новые теги внутри цитат → авторы. Он охватывает связанный с начальными тегами участок каталога. Ключ цитаты - SHA-256 от нормализованного имени автора в нижнем регистре, LF и текста цитаты. Регистр текста сохраняется. Ключ связи - пара *(business_key, source_tag)*; URL ключом записи не служит.

3. Архитектура и пауки

Проект создан через *scrapy startproject quotes_crawler*. Engine связывает компоненты; Scheduler хранит очередь и фильтрует повторные запросы; Downloader получает HTTP; Spider извлекает поля; Item Pipeline проверяет и сохраняет записи. Feed Exports формирует JSONL, Stats Collector собирает счётчики, HTTP Cache воспроизводит ответы, SpiderState и JOBDIR сохраняют состояние.

Использованы обычные *Spider*: *quotes* для десяти страниц и *tags* для графа тегов. Явные *parse* и *parse_item* удобны для разных схем списка и карточки; правила CrawlSpider здесь усложнили бы передачу контекста. Пагинация выполняется через *response.follow*, контекст - через *cb_kwargs*; ожидающие цитаты одного автора объединяются. Автор скачивается один раз за прогон, его сведения сохраняются в состоянии. Селекторы используют классы и атрибуты, индексных XPath нет. Проверки *.get()* и адресов тегов пропускают повреждённые ссылки без исключения, увеличивая *tag/invalid_url*; *errback* учитывает *errors/request* и затронутые цитаты.

4. Item Pipeline

Приоритет	Обработка и счётчики
100	Проверка обязательных полей, включая строки из пробелов; *DropItem*, *dropped/missing_fields*
200	Пробелы, нижний регистр тегов, дата ISO, номер страницы int, бизнес-ключ; *dropped/invalid_value*, *quality/empty_tags*
300	Дедупликация цитат по автору и тексту, связей по цитате и тегу; *dropped/duplicate* / *dropped/duplicate_relation*
400	Одно соединение в open/close, *executemany* пакетами по 20; остаток записывается при закрытии; *database/rows_written* / *database/relations_written*

SQLite содержит *quotes* и *quote_tags*. Основной пайплайн обновляет цитаты через INSERT OR REPLACE; теговый добавляет связь и использует INSERT OR IGNORE для уже известных цитат, сохраняя исходную страницу и время основного сбора. Соединение внутри *process_item* не открывается. Счётчики связей разделены на попытки, реальные вставки и пропуски: *relations_attempted*, *relations_written*, *relations_ignored* в группе *database/*. Повтор 190 связей дал 0 вставок и 190 пропусков (*data/replay_relations.json*); это проверка пайплайна без сети. Пробельные поля, неправильные типы, даты и ссылки покрыты регрессионными тестами.

5. Настройки и ограничение нагрузки

Настройка	Значение и причина
ROBOTSTXT_OBEY / USER_AGENT	True; PGU-DataMining-Lab5 с указанием учебного назначения
CONCURRENT_REQUESTS / PER_DOMAIN	4 / 2; ограничение одновременной нагрузки
DOWNLOAD_DELAY	Базовое значение 0,35 с; случайный множитель 0,5-1,5 по умолчанию
AutoThrottle	Включён; target=1, start=0,35 с, max=5 с; адаптация к времени ответа
DOWNLOAD_TIMEOUT	20 с; ограничение ожидания отдельного запроса
RETRY_TIMES / HTTP_CODES	2 повтора; 408, 429, 500, 502, 503, 504, 522, 524
DEPTH_LIMIT	12; хватает для десяти страниц списка и карточки; ограничивает обход
CLOSESPIDER_ITEMCOUNT / TIMEOUT	300 цитат у quotes, 10 000 связей у tags; 900 с у обоих
HTTPCACHE_ENABLED	False для сетевых замеров; True в опытах кэша и JOBDIR
HTTPCACHE_EXPIRATION_SECS	0; без истечения в изолированном учебном опыте
LOG_LEVEL	INFO; DEBUG для аудита запросов JOBDIR

В *settings.py* даны комментарии к значениям. В колбэках нет блокирующего *time.sleep*. Для теста остановки лимит записей переопределён на 20; фактически завершилось 34 записи, потому что после начала закрытия были обработаны уже запущенные ответы.

6. JOBDIR и HTTP-кэш

Прогон	Записи	Время, с	Cache store	Cache hit	Dupefilter
cache_cold	100	27,589	61	0	0
cache_warm	100	3,037	0	61	0
job_pause	34	0,593	0	23	0
job_resume	66	0,805	0	39	1

Два запуска кэша используют отдельные JOBDIR и одну директорию HTTP Cache: первый сохранил 61 ответ, второй прочитал 61 ответ без новых загрузок. Оба получили по 100 записей. Холодный прогон включает 10 списков, 50 авторов и проверку robots.txt. Сравнение относится к одному измерению на сохранённом наборе.

Остановка JOBDIR завершилась с *closespider_itemcount*. Содержимое состояния до продолжения сохранено в *data/jobstate_paused_listing.json*: очередь запросов, отпечатки *requests.seen*, *spider.state*. Повтор с тем же JOBDIR добавил 66 цитат; SQLite содержит 100 уникальных ключей. Стартовый URL был отфильтрован: *dupefilter/filtered=1*. В *data/job_audit.json* зафиксированы 22 посещённых URL до остановки и 38 после неё; пересечение равно нулю, robots.txt исключён. Это подтверждает отсутствие повторного обхода страниц, а не только наличие счётчика.

Возобновление проверено после штатного закрытия Scrapy; восстановление после повреждения файлов или внезапного отключения питания не проверялось. Очереди разных экспериментов разделены. Файлы *data/stats_*.json* сохраняются в *closed()* после закрытия пайплайна, поэтому учитывают последнюю неполную пачку SQLite.

7. Качество данных и расширенный обход

В *quotes* 100 строк, 100 ключей и 100 различных пар «автор-текст»; дублей нет. Основной сбор обработал десять страниц и 50 авторов. Полнота вычислена для сохранённых строк после DropItem; она не подменяет счётчики потерь на этапе сбора.

Поле	Полнота, %	Поле	Полнота, %
business_key	100	quote	100
author	100	tags_json, непустой массив	97
author_url	100	born_date	100
born_location	100	biography	100
source_url	100	list_page	100
collected_at	100	Обязательные скалярные поля	100

Три цитаты на сайте не имеют тегов: пустой массив сохранён как допустимое значение. Даты приведены к YYYY-MM-DD, *list_page* - INTEGER, теги - JSON-массивы строк. Некорректных дат и бизнес-ключей нет. Итоговые прогоны не отбрасывали записи из-за отсутствующих или некорректных скалярных полей.

Прогон	Коды HTTP и количество	Повторы	Отброшено
cache_cold	200: 60; 404: 1	0	0
cache_warm	200: 60; 404: 1	0	0
benchmark30	200: 23; 404: 1	0	0
tags	200: 160; 404: 1	0	73 повторные связи

HTTP 404 относится к robots.txt; карточки успешно обработаны. Коды и байты downloader в прогоне с кэшем включают кэшированные ответы. Основной холодный обход занял 27,589 с: 19 246 байт запросов и 105 763 байт ответов, всего 0,125009 МБ. Теговый обход занял 70,165 с, обработал 114 страниц тегов и 45 авторов, 161 HTTP-операцию. *dropped/duplicate_relation=73*, *dupefilter/filtered=867*: повторы ссылок и повторы связей - разные счётчики.

Теговый обход сохранил 190 связей для 69 цитат и 99 тегов. Основной каталог содержит 232 связи для 97 цитат и 137 тегов: 42 связи недостижимы из выбранного начального участка графа, лишних связей нет. У всех 69 достигнутых цитат найдены все их теги. Ещё три цитаты не имеют тегов. Покрытие подтверждено в *data/tag_coverage.json*; теговый обход не считается полной заменой десятистраничному.

Примеры агрегатов: Albert Einstein - 10 цитат, J.K. Rowling - 9, Marilyn Monroe - 7; теги love - 14 цитат, life и inspirational - по 13. В ноутбуке также рассчитано распределение по векам рождения авторов. Это характеристики учебного каталога. *quality/quality_report.ipynb* выполнен целиком и содержит таблицы, графики и сверку 30 записей с n8n; результаты сохранены в *quality/current.json* и *completeness.csv*.

8. Конвейер n8n

Manual start / Daily schedule → HTTP Request с пагинацией трёх страниц → HTML Extract → Split Out → подготовка контекста → Loop Over Items по одному → HTTP автора → HTML Extract → проверка полей → Wait 0,5 с → Remove Duplicates → Code с типизацией → CSV → Save CSV. Перед дедупликацией нормализуются пробелы в имени автора и тексте цитаты; окончательное приведение даты к ISO и тегов к нижнему регистру выполняется после неё. Невозможные календарные даты отклоняются, пустой массив тегов допустим. Расписание настроено на 08:00 Asia/Yekaterinburg; workflow оставлен неактивным, проверен ручной запуск.

В сетевых узлах задан Retry On Fail, максимум три попытки. Ошибки HTTP, структуры и типов записываются в *error_log.csv*; HTTP POST доставляет уведомление отдельному локальному приёмнику *127.0.0.1:5686*. Открытая панель браузера показывает сообщение и сохраняет *notifications.jsonl*. В тесте #9 приёмник подтвердил доставку кодом 201; при выключенном приёмнике тест #10 завершился сообщением *local notification FAILED*. Скриншоты ошибки и уведомления приложены. После ошибки прежний успешный CSV остаётся, поэтому требуется проверять статус последнего запуска.

Успешное выполнение n8n #8 получило 30 уникальных цитат со страниц 1-3 за 33,100 с; дата рождения, место и биография совпали со Scrapy. Экспорт - *nocode/workflow.json*, CSV - *nocode/nocode_result.csv*, показатели и ID - *metrics.json* и *execution_summary.json*. Скриншоты *screenshot_workflow.png*, *screenshot_execution.png*, *screenshot_history.png* сделаны в реальном интерфейсе. Искусственные сбои описаны в *error_test.json*; *validation_tests.json* содержит девять проверок кода узлов.

9. Сравнение на одинаковых 30 цитатах

Метрика	Scrapy	n8n
Время разработки, мин	12,95	13,91
Записей собрано	30	30
Время прогона, с	9,481	33,100
Записей в минуту	189,86	54,38
HTTP-операции с robots	24: 3 списка, 20 авторов, robots	34: 33 успешных ответа и отдельный robots
Трафик, десятичные МБ	0,047791 запросы + ответы downloader	0,149517 декодированные тела HTML
Дедупликация запросов	Scheduler и кэш автора в состоянии	Запрос автора для каждой цитаты
Возобновление после сбоя	Проверено JOBDIR	Сохранённая история; повтор запуска, без курсора
Расписание и оповещения	Внешний планировщик; в проекте не настроен	Триггер настроен; журнал и уведомление в локальной панели
Версионирование логики	Файлы Python и settings	Экспорт JSON; изменение отражается в Git
Усилия поддержки, 1-5	3, оценка	2, оценка

Время разработки - сумма зафиксированных интервалов работы над проектом: первоначальная работа и последующие исправления. Для Scrapy это 9,97 + 2,98 мин; для n8n - 9,23 + 4,68 мин. Включены установка, эксперименты, тесты и ожидания; работа велась параллельно. Это не человеко-минуты. Исходные метки сохранены в *development_scrapy.json* и *development_n8n.json*.

В Scrapy подсчитаны 24 операции downloader без кэша и перенаправлений. n8n фиксирует 33 успешных ответа узлов и отдельный robots 404; реальные сетевые попытки и повторы непосредственно не инструментированы. Базы подсчёта трафика различаются: Scrapy учитывает заголовки и сжатые тела, n8n - UTF-8 длины декодированных HTML без заголовков. Эти числа нельзя использовать как доказательство большей экономии трафика. На время также влияют дедупликация авторов и задержки 0,35/0,5 с; один замер не устанавливает общую скорость инструментов.

10. Выбор инструмента для трёх сценариев

Для разового обхода 500 страниц выберу Scrapy: уже реализованы пагинация, повторное использование карточек, проверяемый экспорт и контроль качества. При готовом простом API и существующем n8n-сценарии стоимость сборки могла бы изменить выбор; здесь измерена именно HTML-обработка.

Для ежедневных 40 000 страниц выберу Scrapy с постоянной БД, очередями заданий, журналами и мониторингом. JOBDIR помогает после штатной остановки, но не заменяет резервное копирование и управление распределённой очередью. Масштабирование не отменяет правила источника и ограничения нагрузки.

Для сбора со ста страниц и отправки отчёта в мессенджер выберу n8n при простой структуре источника: расписание, ветвление и интеграции собираются в одном workflow. Предлагаемый гибрид - n8n запускает Scrapy через Scrapyd/API, отслеживает статус, читает сводку качества и отправляет отчёт. В данной работе гибрид и отправка в мессенджер не реализованы.

11. Редизайн и smoke-check

Смена классов может дать пустые селекторы без HTTP-ошибки; новый формат даты - рост *dropped/invalid_value*; изменение пагинации - меньше страниц и записей. Проверяются структура карточки, обязательные поля, стабильный бизнес-ключ и итоговый объём. Индексные XPath не применяются. Теговый граф дополнительно может потерять связность: его покрытие сравнивается с полным каталогом, а не оценивается по числу переходов.

quality/smoke_check.py previous.json current.json выдаёт предупреждение и код 1 при падении числа записей более чем на 20% или доле пустых обязательных ячеек более 5%; ровно 20% и 5% проходят. Доля - число пустых обязательных ячеек, делённое на число таких ячеек во всех строках. Нули и пустые необязательные теги не являются пропусками. Несовместимые окна сбора и некорректные снимки дают код 2.

Сравнение независимых полных прогонов 100 → 100 завершилось без предупреждения. Проверки границ, 100 → 79, 5,01% пустот и пустого набора выполнены на синтетических примерах (*smoke_demonstration.json*); это не реальные сбои сайта. Умеренный рост DropItem при сохранении объёма может пройти этот порог, поэтому в статистике отдельно анализируются причины отброса. Сравнение с накопленной исторической таблицей вместо текущего прогона могло бы скрыть деградацию; для исходного снимка используется отдельная база холодного опыта.

12. Правовая и этическая оценка

Используется учебная площадка Quotes to Scrape; авторизация, обход капчи и антибот-защиты не применяются. Scrapy запрашивает robots.txt при *ROBOTSTXT_OBEY=True*; сервер вернул 404, опубликованных запретов в нём не получено. Проверка n8n дала тот же статус. Ответ 404 не является лицензией на произвольную обработку данных. Нагрузка ограничена параллелизмом, задержками, AutoThrottle, кэшем и предохранителями.

Имена, даты и места рождения и биографии относятся к сведениям о физических лицах. Публичная доступность не означает автоматического разрешения на любое использование или распространение; учебное назначение само по себе не отменяет требования 152-ФЗ. Данные хранятся локально для воспроизведения задания, контакты и сведения пользователей не собираются. Для использования вне учебного упражнения необходимо отдельно проверить основание обработки, цели, сроки хранения и права на тексты. Общедоступность страницы и соблюдение robots.txt решают разные вопросы.

13. Источники

ТЗ лабораторной работы 5 и Excel с вариантами из папки «ПапкиДляТЗ»; вариант 3. Демонстрационный Colab занятия 5; пример оформления лабораторной 3; пример обхода тегов, вариант 4.

Учебные площадки ToScrape, Quotes, страница 11. Scrapy: архитектура, Item Pipeline, AutoThrottle, JOBDIR, HTTP Cache. n8n: HTML, Loop Over Items. 152-ФЗ, публикация Минтруда.