Лабораторная 6. Хранение, очистка и структура данных

1. Цель и вариант

Вариант 3: цитаты и авторы. Собрано общее хранилище для HTML и API: сырые записи сохраняются отдельно, чистые проверяются контрактом, аналитические представления строятся только при допустимом качестве.

2. Источники и слои

HTML-набор из пятой работы содержит 100 цитат и теги; год рождения получен из ранее посещённых страниц авторов. В исходном HTML сохранены значения до очистки и разметка карточки. Для объёма от 300 записей добавлен учебный DummyJSON: четыре порции по 80 цитат. API содержит текст и имя автора, но не теги и дату рождения. Это новый дополнительный источник: API третьей работы был Open Library; DummyJSON расширяет исходный корпус до нужного объёма. Недостающие сведения не выдумываются.

Добавлены 32 явно помеченные учебные записи с пробелами, дублями, пропусками и ошибками: 7,08% от 452 входных строк. Эти случаи не выдаются за новые цитаты источника.

Схема: raw (JSONL и происхождение) → clean (контракт, Parquet, rejects) → SQLite и mart (агрегаты и партиции). В каждой сырой строке есть _source, _source_url, _collected_at в UTC, _parser_version и _status. Manifest хранит размер и SHA-256 прежних байтов; разрешена дозапись, изменение старых строк отклоняется. Команда python -m src.rebuild работает без обращения к сайтам. Повторная проверка подтвердила сохранность raw.

3. Сравнение форматов

Тот же набор из 414 строк записан в три формата. Время - медиана семи последовательных чтений на этом ПК; это замер небольшого набора с прогретым файловым кэшем.

Формат	Размер, байт	Всё, мс	3 столбца, мс
CSV	137434	8.35	6.23
JSONL	209284	20.97	21.09
Parquet	72574	6.15	4.21

CSV возвращает дату как object, JSONL и Parquet - datetime с UTC. При автоматическом чтении Pandas строковый ID 000100 превращается в 100 в CSV и JSONL. В самом JSONL строка сохранена: потеря нулей происходит из-за вывода типа читателем. Для них нужен явный dtype. Parquet сохраняет string и 000100.

Для raw выбран JSONL: построчная дозапись и сохранение происхождения. Для clean и mart - Parquet: типы, списки тегов и выбор столбцов. CSV оставлен для просмотра и обмена.

4. Протокол очистки

Этап	До	После	Изм.	Удал.	Примечание
1. Нормализация текста	452	452	17	0	NFKC, NBSP, zero-width, пробелы
2. Бизнес-ключ и URL	452	452	452	0	SHA-ключ у всех строк; tracking-URL: 8
3. Типизация	452	446	446	6	UTC, числовой год, строковый ID; ошибки в rejects
4. Пропуски	446	434	0	12	Текст, автор и URL обязательны; неизвестный год = NULL
5. Полные, ключевые и почти-дубли	434	420	0	14	Сохранена самая свежая запись
6. Бизнес-правила и контракт	420	414	0	6	Полный pydantic-контракт; поле и причина в rejects

Текст проходит NFKC, удаление неразрывных и zero-width пробелов и схлопывание пробелов. Ключ - SHA-256 нормализованной пары автор + цитата; из URL удаляются параметры трекинга. Даты приводятся к UTC, целые с пропусками - к Int64. Денежных полей в этом варианте нет. Обязательные пропуски отбраковываются, необязательный год рождения остаётся NULL. Средние значения вместо пропусков не используются.

Полные, ключевые и почти-дубли сравниваются по тексту и автору без различий регистра и пунктуации; сохраняется свежая запись. В сумме удалены 14 дублей и отбракованы 24 строки: шесть с неверной датой, 12 с обязательными пропусками и шесть с неверными тегами. После очистки осталось 414 уникальных цитат.

5. Контракт данных

Модель Quote находится в src/contract.py. Проверяются длина текста и имени, формат ключей, число и форма тегов, UTC и отсутствие будущей отметки сбора. field_validator проверяет текст, теги и дату; model_validator связывает ключ с текстом и автором, проверяет длину и соответствие URL источнику. Правила: 1) текст 8-2000 символов без HTML; 2) имя 2-150 символов; 3) до 20 тегов-slug; 4) UTC и допустимое время сбора; 5) SHA-ключ соответствует автору и цитате; 6) ключ автора соответствует имени; 7) длина равна тексту и URL принадлежит указанному источнику. Ошибки сохраняются с полем, причиной и исходным payload в rejects.jsonl.

Проверка	Результат	Сообщение
Пустой текст	отклонено	String should have at least 8 characters
Короткое имя	отклонено	String should have at least 2 characters
Неверный тег	отклонено	Value error, Тег должен быть непустым slug в нижнем регистре
Дата без зоны	отклонено	Value error, Нужен часовой пояс UTC
Неверный ключ	отклонено	Value error, Бизнес-ключ не соответствует тексту и автору
Неверная длина	отклонено	Input should be greater than 7
Неверный источник URL	отклонено	Value error, URL не соответствует источнику

Все 414 итоговых записей дополнительно проверены той же моделью.

6. SQLite, ключи и история

В schema.sql описаны authors, quotes, quote_tags, rejects и quote_history. Ключ цитаты - первичный; author_key связан внешним ключом с авторами. Пара источник + исходный ID уникальна. NOT NULL и CHECK защищают обязательные поля, длины и диапазоны. Связи: authors 1 → N quotes; quotes 1 → N quote_tags и quote_history. rejects хранит отдельный брак с исходным payload. Индексы idx_quotes_author, idx_quotes_source и idx_tags_tag используются в соответствующих агрегатах.

Пакетный UPSERT сравнивает хэш значений. Если содержимое не изменилось, строка и updated_at не обновляются. UTC канонизируется до вычисления хэша, поэтому Z и +00:00 не создают ложных изменений. История хранит полный снимок только при первом появлении или изменении записи. Для небольшого набора с редкими изменениями снимок позволяет восстановить значения по ключу и времени без сложных интервальных запросов.

Отдельная idempotency_demo.db содержит три прогона. В третьем учебно изменены теги двух записей; основная warehouse.db содержит исходный чистый набор.

Загрузка	Строк	Вставлено	Обновлено	История
A	414	414	0	414
B	414	0	0	414
C	414	0	2	416

В повторе updated_at сохранился у всех 414 строк. Попытки нарушить CHECK, вставить дублирующийся ключ и записать NULL в обязательное поле завершились отказом SQLite.

7. Качество и светофор

Метрика	Значение	Зелёный	Жёлтый	Статус
Обязательные поля	100.00%	≥100.00%	≥99.00%	green
Год рождения автора	22.71%	≥10.00%	≥5.00%	green
Уникальность ключа	100.00%	≥100.00%	≥99.00%	green
Валидность сырых записей	94.69%	≥90.00%	≥80.00%	green
Доля отбраковки	5.31%	≤10.00%	≤20.00%	green
Бизнес-правила	100.00%	≥100.00%	≥99.00%	green
Медианный возраст, дней	0.26	≤30.00	≤60.00	green
Изменение объёма	0.00%	≤10.00%	≤20.00%	green

Каждая из 452 сырых строк отдельно проходит очистку и полный контракт; прошли 428: 428 / 452 = 94,69%. Дедупликация затем уменьшает чистый слой до 414. Метрика бизнес-правил повторно проверяет весь контракт, а не только длину. Красный - значение ниже жёлтого минимума либо выше жёлтого максимума. Порог отбраковки учитывает намеренно внесённые дефекты до 10%. Год рождения необязателен и доступен только у части авторов; его порог не равен порогу обязательных полей. Возраст оценивается по медиане, поскольку это учебные метаданные, а не оперативные наблюдения.

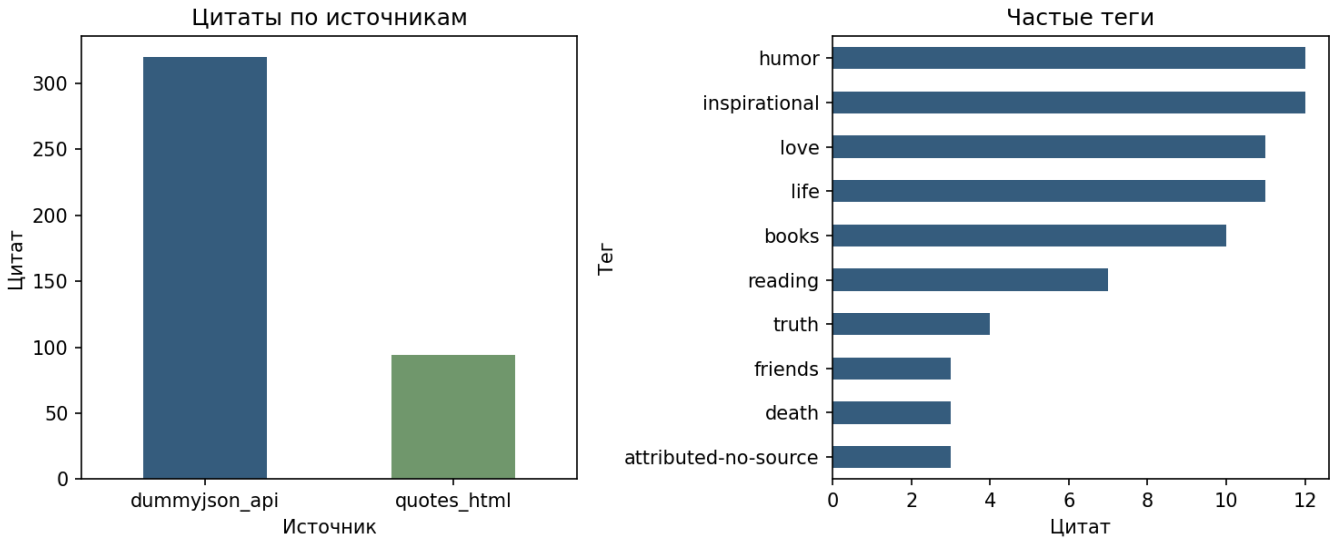
Итог - green. Функция require_mart останавливает загрузку при красной метрике. Демонстрация --force-red вернула код 2; хэши raw и mart до и после совпали.

8. Аналитический слой

Получены 414 цитат, 98 авторов и 205 связей с тегами. Созданы три SQL-представления и их Parquet-выгрузки: цитаты по авторам, по источникам и частые теги. В чистом наборе 94 строки HTML и 320 API.

Снапшоты разделены по дате сбора в mart/snapshots/dt=… . Проверка читает одну выбранную партицию через фильтр Parquet; результат записан в partition_read.json. При пересборке затронутые партиции заменяются, имена файлов стабильны: повтор не дописывает те же цитаты. Две пересборки дали по 414 строк и 414 уникальных ключей, файлы партиций совпали; snapshot_validation.json.

Цитаты по источникам и частые теги



9. Код и n8n

n8n читает 39 подготовленных строк из обоих источников. Normalize fields очищает текст и имя, приводит дату и строковый ID; Crypto считает SHA-ключ. IF отделяет три невалидные строки, Remove duplicates удаляет два повтора. На выходе - 34 строки, их ключи, тексты и авторы совпали с Python. CSV создаётся самим n8n; отдельного скрипта очистки после экспорта нет.

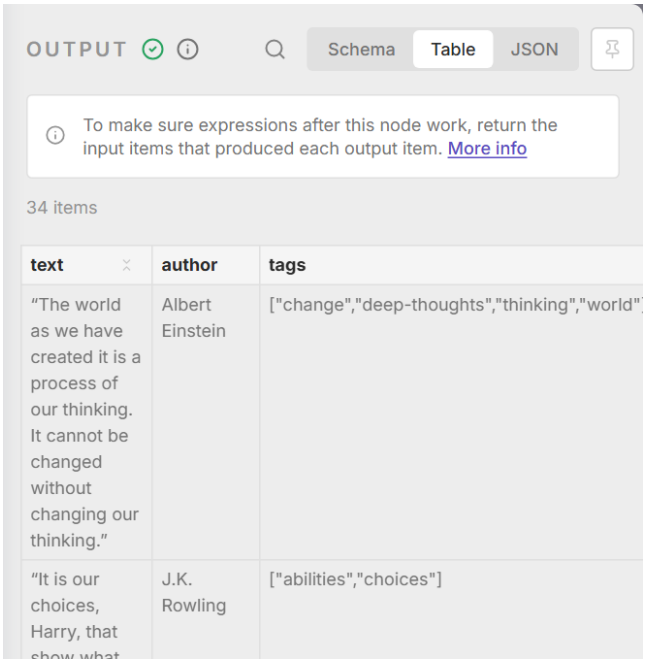
Этап	Python	n8n	Ограничение n8n-сценария
Raw	JSONL, контроль прежних байтов	Чтение подмножества	Нет контроля append-only
Нормализация	NFKC, URL, UTC, nullable	Code и Crypto, 3+ поля	Не все типы и URL-правила
Контракт	Полная модель pydantic	IF, основные проверки	Нет полной модели согласованности
Дубли и брак	Ключ, почти-дубли, rejects	Remove duplicates, IF, CSV	Нет поиска почти-дублей
БД и история	SQLite UPSERT и снимки	CSV	Нет UPSERT и истории в CSV
Mart и качество	8 метрик, пороги, партиции	Не реализовано	Нет светофора и mart
Расписание	Внешний запуск	Daily schedule	Ручной прогон проверен

Для UPSERT из n8n нужна ветка загрузки в Postgres/MySQL либо отдельный интерфейс БД. В выбранном CSV-экспорте такой операции нет. Это ограничение данного сценария, а не всей платформы.

10. Результат n8n

Время успешного исполнения - 0.865 с по startedAt/stoppedAt n8n, без импорта workflow и опроса API. Успешный результат и отвергнутые строки сохранены отдельно. Схема workflow, экспорт JSON, таблица CSV.

Успешный прямой экспорт n8n: 34 строки



11. Правовая оценка и вывод

Цель - учебная проверка хранения и качества данных. Источники предназначены для обучения и тестирования. Сохраняются тексты цитат, имена, теги и доступный год рождения; адреса, контакты и полные биографии в это хранилище не перенесены. Имена и год рождения рассматриваются как потенциальные персональные данные, а авторство цитат отдельно не проверялось.

Для учебной научной деятельности рассмотрен п. 8 ч. 1 ст. 6 152-ФЗ с соблюдением прав человека. Открытая страница сама по себе не разрешает любое распространение текста или персональных сведений. Для GDPR отдельно учитываются территориальная применимость, принципы минимизации и ограничения хранения из статьи 5 и необходимость основания из статьи 6.

Файлы хранятся локально и в учебном репозитории. Предлагаемый срок - до 30 дней после проверки; удаление должно учитывать raw, кэши, БД, резервные и версионные копии. Для дальнейшей публикации достаточно агрегатов.

Выбран Python с SQLite и Parquet: он сохраняет контракт, происхождение и историю. n8n подходит для расписания и небольшого экспорта, но в этой реализации не заменяет слой качества.

Источники

- DummyJSON Quotes, Quotes to Scrape.

- Pydantic: validators.

- SQLite UPSERT, Apache Arrow Parquet.

- n8n Remove Duplicates.

- 152-ФЗ, GDPR.