Лабораторная работа № 6

Хранение, очистка и структурирование собранных данных

ПМИ-2-2025. Вариант 3.

1. Цель и вариант

Построить воспроизводимое хранилище цитат и авторов: raw → clean → mart, с контрактом данных, историей в SQLite и контролем качества. В таблице вариантов указан номер 26: (26 mod 6) + 1 = 3. Чистый слой содержит 420 цитат, что превышает минимум 300.

2. Источники и их различия

Использованы сохранённые снимки из локального архива предыдущих работ, новый сбор для выполнения этой работы не потребовался.

Источник	Состав и происхождение	Отличия
HTML Quotes to Scrape	100 цитат, страницы 1–10, снимок лаб. 5	Текст, автор, теги, исходная html_raw карточка, год рождения из сохранённых сведений автора
API DummyJSON Quotes	320 цитат, 4 страницы по 80, api_raw	JSON: id, quote, author, теги отсутствуют, год рождения NULL

DummyJSON — дополнительный сохранённый учебный API, а API лабораторной № 3 был Open Library. Все 320 объектов api_raw совпали с текущими значениями DummyJSON при контрольной сверке. Даты в raw относятся к архивному сбору, а не к этой сверке. Имена и авторство передаются как сведения источника, без проверки атрибуции. Добавлены 32 явно помеченных дефектных копии (_synthetic, _injected_reason): 7,08% от 452 входных строк, они не создают новые цитаты.

3. Схема трёхслойного хранилища

raw/*.jsonl → шесть шагов очистки + pydantic → clean/*.parquet и rejects → SQLite UPSERT → проверка светофора → mart/views и snapshots/dt=дата. Сырые строки содержат _source, _source_url, _collected_at (UTC ISO 8601), _parser_version, _status. Для HTML сохранены все целевые *_raw и карточка. manifest.json проверяет SHA-256 прежнего префикса: дозапись допустима, изменение прежних байтов останавливает пересборку. Это программная проверка, а не файловая защита от владельца диска.

Команда python -m src.rebuild читает только локальный raw, повтор сохранил 420 строк, хэши raw и число строк партиций. Полные результаты и исполняемые проверки находятся в quality_report.ipynb.

4. Сравнение форматов

Один набор из 420 строк, без искусственного размножения. Время — медиана 7 чтений с прогретым файловым кэшем, столбцы: source_record_id, collected_at, text_length.

Формат	Байт	Всё, мс	3 столбца, мс	Дата, ID после чтения
CSV	140071	2.81	2.03	object, int64, 100
JSONL	215575	5.92	6.10	UTC datetime, int64, 100
Parquet	74376	2.66	1.84	UTC datetime, string, 000100

Автовывод типов pandas теряет нули 000100 в CSV и JSONL, JSONL сам хранит строку корректно. Явные dtype, UTC и декодирование списка восстанавливают одинаковые значения всех строк (format_roundtrip.json). Raw выбран JSONL для дозаписи и исходных полей, clean и mart — Parquet для типов, списков и чтения выбранных столбцов. CSV служит обмену. Замер на малом наборе не доказывает универсального превосходства по скорости.

5. Протокол очистки

Шаг	До	После	Изменено	Удалено
1. Нормализация текста	452	452	17	0
2. Бизнес-ключ и URL	452	452	452	0
3. Типизация	452	446	446	6
4. Пропуски	446	434	0	12
5. Полные, ключевые и почти-дубли	434	420	0	14
6. Бизнес-правила и контракт	420	420	420	0

Текст: NFKC, удаление NBSP и zero-width, схлопывание пробелов. Ключ цитаты — SHA-256 строки source + '|' + source_record_id, ключ автора — хэш имени. Пространство имён источника исключает совпадение его ID с другим сервисом. Исправления текста, тегов и даты сохраняют ключ цитаты, автоматическое объединение разных написаний имён не выполняется. Источниковый ID остаётся строкой с ведущими нулями. Даты timezone-aware UTC, год рождения nullable Int64, денежных полей в варианте нет. Обязательные пропуски отбраковываются, необязательные остаются NULL, среднее не подставляется.

На шаге 5 образованы 420 групп, 14 альтернатив сохранены для проверки. На шаге 6 контракт проверяет всех кандидатов и выбирает самый свежий валидный. В 6 группах дефектная свежая копия отклонена, сохранена корректная старая. Поэтому 14 альтернатив в журнале дублей включают 8 валидных дублей и 6 отклонённых записей. Непересекающийся баланс: **452 = 420 принятых + 24 отклонённых + 8 дублей** (raw_disposition.json). Причины брака: 6 неверных дат, 12 обязательных пропусков, 6 неверных тегов. Все удаления имеют исходный payload и причину, изменено означает преобразованные записи, включая построение типизированной записи на шаге 6.

6. Контракт данных и демонстрация ошибок

Модель Quote в src/contract.py задаёт обязательность, типы, min_length, gt/le и диапазон года. Три field_validator проверяют очищенный текст, slug-теги и дату UTC, model_validator связывает бизнес-ключ с ID источника, ключ автора с именем, длину текста и домен URL. Доменные правила: текст 8–2000 символов, имя 2–150, не более 20 тегов-slug, допустимый год рождения, дата UTC не из будущего, соответствие ключей содержимому, длина равна тексту, URL соответствует источнику. Каждый из 420 итоговых объектов прошёл тот же контракт.

Проверка	Результат	Сообщение об ошибке
Пустой текст	отклонено	String should have at least 8 characters
Короткое имя	отклонено	String should have at least 2 characters
Неверный тег	отклонено	Тег должен быть непустым slug в нижнем регистре
Дата без зоны	отклонено	Нужен часовой пояс UTC
Неверный ключ	отклонено	Бизнес-ключ не соответствует источнику и ID
Неверная длина	отклонено	Input should be greater than 7
Неверный источник URL	отклонено	URL не соответствует источнику

В rejects.jsonl и таблице rejects сохраняются raw_index, этап, поле, причина, признак учебного дефекта и payload. Неизвестные теги API представлены пустым списком, а не придуманными значениями.

7. База данных и история изменений

schema.sql описывает authors (ключ автора), quotes (бизнес-ключ), quote_tags (составной ключ цитата + тег), rejects и quote_history. Связи authors 1:N quotes, quotes 1:N quote_tags/history. Обязательные поля защищены NOT NULL, длины и диапазоны — CHECK, UNIQUE(source, source_record_id) запрещает повтор идентификатора источника. Внешние ключи включены. Индексы author_key, source и tag соответствуют запросам трёх представлений.

Пакетный executemany выполняет ON CONFLICT DO UPDATE с условием изменения хэша. При одинаковом содержимом updated_at сохраняется. quote_history записывает полный снимок при первой загрузке и при изменении, для малого набора это проще интервальной SCD2. Неизменный бизнес-ключ сохраняет историю правок текста и метаданных. Загрузка принимает полный clean-снимок, отсутствующие ключи остаются в БД с is_active=0, а вернувшиеся активируются. Все три представления учитывают только is_active=1, это сохраняет соответствие mart чистому снимку при смене победителя среди почти-дублей.

Три прогона выполнены в отдельной демонстрационной БД, основная warehouse.db содержит исходный чистый набор. В C учебно изменены теги двух цитат.

Прогон	Строк	Вставлено	Обновлено	Без изменений	История
A	420	420	0	0	420
B	420	0	0	420	420
C	420	0	2	418	422

В B все 420 updated_at сохранились, в C изменились ровно два ключа, история выросла на две строки. INSERT с text_length=0 отклонён CHECK, дублирующий business_key — PRIMARY KEY, NULL текста также отклонён. Подробные сообщения SQLite сохранены в idempotency.json. Проверки не меняют warehouse.db.

8. Метрики качества и светофор

Метрика	Значение	Зелёный	Жёлтый	Статус
Обязательные поля	100.00%	≥100%	≥99%	зелёный
Год рождения	23.81%	≥10%	≥5%	зелёный
Уникальность ключей	100.00%	≥100%	≥99%	зелёный
Валидность raw	94.69%	≥90%	≥80%	зелёный
Доля отбраковки	5.31%	≤10%	≤20%	зелёный
Бизнес-правила	100.00%	≥100%	≥99%	зелёный
Медианный возраст, дней	12.84	≤30	≤60	зелёный
Изменение объёма	0.00%	≤10%	≤20%	зелёный

Красный — выход за жёлтый предел. Обязательные поля и ключи требуются полностью, год рождения есть лишь у HTML, поэтому его отдельный минимальный порог 10%. Валидность 428/452 проверяет каждую сырую строку после нормализации до дедупликации, принятый набор меньше из-за дублей. Пределы брака 10/20% учитывают 7,08% учебных дефектов. Возраст 30/60 дней выбран для учебного справочного набора. Допуск объёма 10/20% обнаруживает пропуски страниц. На первом запуске сравнение объёма отмечено как bootstrap, на повторе предыдущий объём равен 420.

Итоговый вердикт — **зелёный**. require_mart прекращает построение при красном показателе с его названием. Контроль --force-red завершился кодом 2, хэши всех файлов mart сохранились (red_gate_evidence.json). Возраст меняется при новом запуске, старый снимок закономерно может перестать проходить порог.

9. Аналитический слой mart

Получены 420 цитат: 100 HTML и 320 API, 101 авторов, 232 связей с тегами. SQL-представления quotes_by_author (число цитат и средняя длина), quotes_by_source (объём и средняя длина), popular_tags (частота тегов) экспортируются в mart/views/*.parquet.

Снимки разделены по дате сбора на две партиции вида dt=YYYY-MM-DD. Чтение только первой партиции через фильтр вернуло 92 строки. Повтор заменяет затронутые файлы партиций, а не дописывает копии. Суммарное число строк и уникальных ключей остаётся 420. Более поздняя дата у части HTML — помеченные учебные копии уже известных цитат, это не новый сбор HTML.

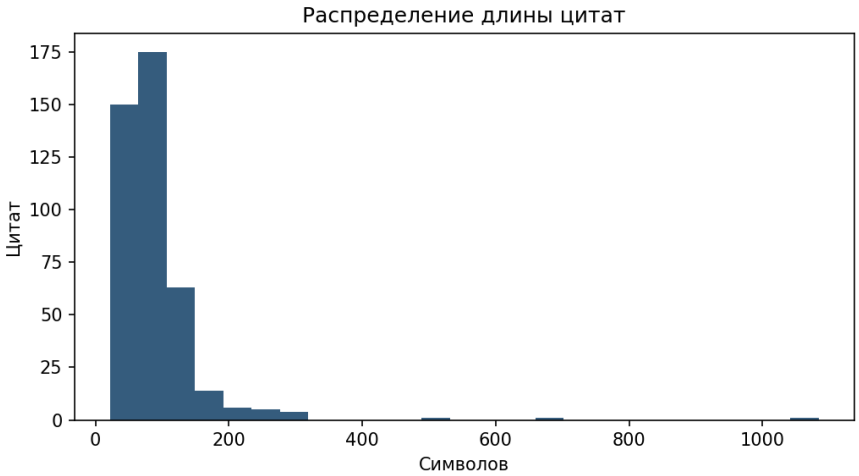


Рисунок 1. Длина текста в символах по чистому набору.

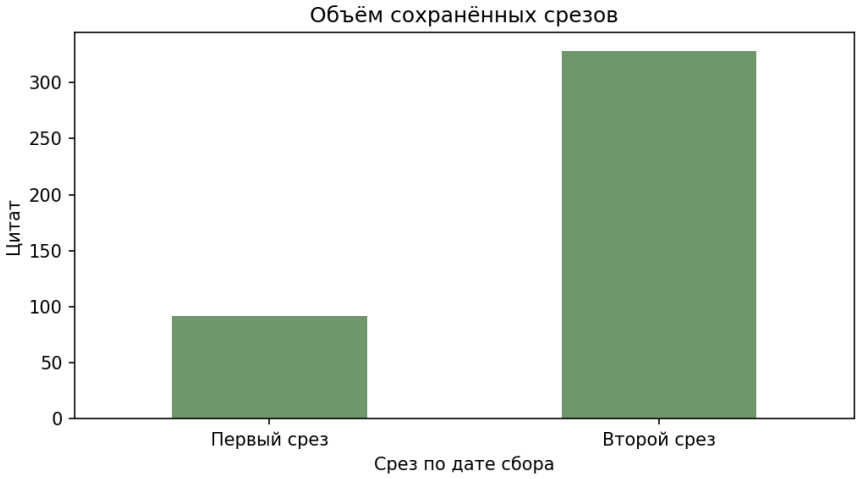


Рисунок 2. Распределение записей по двум сохранённым срезам. Показаны архивные наблюдения и учебные копии, а не изменение популярности или содержания цитат во времени.

10. Сопоставление Python и n8n

n8n обработал 39 входных строк из обоих источников: 34 валидные, 3 отклонённые и 2 дубля. Нормализуются текст, автор, дата и исходный ID, Crypto считает SHA-ключ, IF разделяет потоки, Remove Duplicates удаляет повторы. CSV и отдельный rejects.csv создаёт сам workflow, Python их сверяет с clean. Сохранены workflow.json, реальные screenshot_workflow.png и screenshot_result.png.

Этап	Python	n8n	Ограничение сценария
Raw	JSONL + SHA префикса	Чтение сохранённого поднабора	Нет контроля append-only
Нормализация	NFKC, URL, UTC, nullable	Code + Crypto, 4 поля	Нет полного набора типов/правил URL
Контракт и брак	pydantic + rejects + БД	IF → отдельный CSV	Нет полной межполевой модели
Дубли	Ключ и почти-дубли	Remove Duplicates	Нет почти-дублей и fallback
Загрузка и история	SQLite UPSERT + снимки	CSV с заменой файла	Нет UPSERT и истории в CSV
Качество и mart	8 метрик, gate, партиции	Не реализовано	Нет светофора и mart
Расписание	Запуск команды	Daily schedule 08:00	Для автоматики нужна активация

CSV не поддерживает обновление по ключу, поэтому выбранный экспорт не выполняет UPSERT. Для него требуется Postgres/MySQL Upsert с подключением к БД, это возможность n8n, которая в данном сценарии не настроена. Замена CSV при повторе не считается UPSERT. Ежедневное расписание задано в Asia/Yekaterinburg, workflow экспортирован неактивным. Ручной запуск проверен. Этот сценарий сокращает ручную работу экспорта, но полный слой качества реализован в Python.

11. Правовой раздел

Сохраняются короткие тексты цитат, имена, теги и доступный год рождения. Контакты, адреса, полные биографии и страницы авторов не копируются в сдачу. Имя и год рождения могут быть персональными данными, хэш имени не обеспечивает обезличивание. Публичная доступность сама по себе не является согласием на любое использование или распространение.

Цель — локальная учебная проверка. По 152-ФЗ отдельно оцениваются принципы минимизации (ст. 5), основание обработки (ст. 6) и распространение (ст. 10.1). Пункт 9 ч. 1 ст. 6 для исследования требует обезличивания и не служит автоматическим основанием хранения имён, согласие и иное применимое основание в этой работе не установлены. Применимость GDPR зависит от условий ст. 3, при применимости нужны основание ст. 6 и соблюдение минимизации/сроков ст. 5. Учебная цель не отменяет авторские права на тексты. Поэтому этот комплект предназначен для локальной сдачи, публикация исходных текстов и имён отдельно не обосновывается.

Хранение — локальная папка lab6_3, доступ владельцу и проверяющему. Предлагаемый срок — до 30 дней после проверки, удаление должно охватить raw, БД, CSV, архив и резервные копии. Для дальнейшего распространения достаточно агрегатов без имён и текстов.

12. Источники

1. Quotes to Scrape и DummyJSON Quotes.

2. Демонстрационный блокнот занятия 6 — структура этапов, адаптирован к цитатам.

3. Pydantic validators, SQLite UPSERT, PyArrow Parquet, n8n Remove Duplicates.

4. 152-ФЗ, действующий текст, GDPR, официальный текст.