Лабораторная 7. Устойчивый сбор данных

1. Цель и вариант

Вариант 3: смешанный сбор HTML + API. Обязательные случаи - 500 у одного источника при работающем втором и 404 на части URL. За основу взят HTTP-сборщик третьей работы; HTML-извлечение адаптировано из пятой.

A/B/C выполнены на локальном учебном HTTP-стенде: по 30 ранее сохранённых цитат и книг, всего 60 уникальных записей. HTML пересобран из сохранённых полей, JSON приведён к records. Это управляемые учебные ответы, а не имитация новых обращений к внешним сайтам.

2. Аудит исходного решения

Механизм	Исходный код	Доработка
Session, User-Agent, timeout	Были в сборщике 3	Сохранены
Скорость	Пауза между запросами	Token bucket по доменам и адаптация
Повторы	429/5xx, задержка с добавкой	Full jitter, cap, бюджет URL, Retry-After
Изоляция отказа	Предохранителя не было	Closed / open / half-open
Экономия	Кэш авторов и известные ключи	HTTP 304, gzip, manifest и watermark
Диагностика	Статус и Content-Type	Маркеры, ожидаемые записи, история, пороги

Модули limiter, retry, breaker, detector и observability отделены от collect. Логика и данные находятся внутри lab7; импортов из других лабораторных нет.

3. Скорость и robots.txt

На локальном стенде задано 2 запроса/с, burst 1 и положительный джиттер до 25% интервала. При медианной латентности около 41 мс интервал 0,5 с существенно больше времени ответа; параллельные запросы на один origin не нужны. Задержка пересчитывается по латентности, а при 429/503 увеличивается. Crawl-delay и request-rate имеют приоритет.

Два loopback-адреса представляют независимые учебные источники. Один координатор назначает домен одному воркеру. Межпроцессная файловая блокировка не даёт второму процессу одновременно забрать этот домен; это проверено отдельным процессом. Для четырёх процессов домены нужно распределить между владельцами, а не умножать локальный лимит на четыре. Redis и распределённая очередь в этой работе не используются.

На реальном Quotes robots.txt вернул 404: запрета нет, собственный лимит сохраняется. Получены 10 цитат из настоящего ответа. Open Library вернул robots.txt, но can_fetch для Search URL оказался false: запрос пропущен. Для внешней проверки задано 0,9 запроса/с, ниже базового лимита API в один запрос/с. Данные A/B/C взяты из прежнего сохранённого набора. Для нашего User-Agent Crawl-delay и request_rate не заданы. У Open Library правило User-agent: * / Disallow: /search охватывает /search.json, Sitemap - /static/sitemaps/siteindex.xml.gz; у Quotes robots.txt отсутствует. Исходные правила и повторная проверка сохранены в reports/robots_openlibrary.txt и robots_review.json.

Интервалы начала запросов восстановлены из ts − ms журнала B. Минимум: 0,533 с для HTML и 0,534 с для API; медианы 0,548 и 0,556 с. Обе серии выше базового интервала 0,5 с. Выбор даёт более чем десятикратный запас к медианной латентности около 41 мс; burst 1 исключает одновременный всплеск. Подробности - reports/rate_limits.json.

4. Политика повторов

Ответ или ошибка	Действие	Ограничение
200 / 304	Проверка содержимого или локальная копия	304 без копии считается ошибкой
429	Задержка, повтор	Приоритет Retry-After; число или HTTP-дата
500-599	Повтор и учёт отказа домена	Full jitter: random(0, min(cap, base × 2^attempt))
Сетевая ошибка	Ограниченный повтор	Не более трёх попыток и восьми секунд на URL
401 / 403	Без повтора	Фиксация авторизации или блокировки
Другие 4xx, включая 404	Без повтора	URL записывается в журнал

Для backoff base = 0,25 с, cap = 2 с. Retry-After не обрезается до cap: если ожидание не помещается в оставшийся бюджет URL, запрос прекращается. Каждая попытка и выбранная задержка с её источником записываются в JSONL.

5. Предохранитель и изоляция

После двух последовательных временных отказов домен переходит в open на 1,2 с. Во время паузы запросы не отправляются. Затем разрешается один half-open запрос: успех возвращает closed, новый отказ снова открывает предохранитель.

В сценарии два подготовленных HTTP 500 остановили HTML-источник, а API продолжил работу. В журнале есть circuit_open, skip_open, circuit_half_open и circuit_closed. После паузы HTML-ответ успешно обработан. Два URL с 404 были запрошены ровно по одному разу.

6. Детектор блокировки

Проверяются 403/429, маркеры captcha / access denied / «доступ ограничен», слишком малое тело и отсутствие ожидаемых записей при HTTP 200. 429 даёт подозрение и снижение частоты; явный маркер, 403 или подменённое содержимое - блокировку.

Подготовленная заглушка 200 с CAPTCHA остановила только HTML-домен. Тело и заголовки сохранены в logs/incidents, API продолжил работу. Процесс вернул код 2. Детектор также проверен на настоящем HTML-ответе с десятью цитатами; обхода заглушки не предпринималось.

7. Снижение нагрузки

Ресурсы имеют ETag и Last-Modified. Валидаторы сохраняются в state/etags.json и отправляются как If-None-Match / If-Modified-Since. При 304 используется уже проверенная локальная копия. Слабый ETag и Vary учитывают сжатую и несжатую формы.

Сравнение механизмов выполнено отдельно, относительно B на том же наборе:

Механизм	Запросов до	После	Байт до	После	Экономия, %
Conditional GET	10	10	17826	0	100.00
gzip	10	10	17826	6159	65.45
Watermark	10	4	17826	476	97.33

Байты означают переданные тела ответов, включая gzip в сжатом виде. HTTP-заголовки и транспортные расходы сюда не включены. Поэтому 100% экономии тела при 304 не означает отсутствие сетевого обмена.

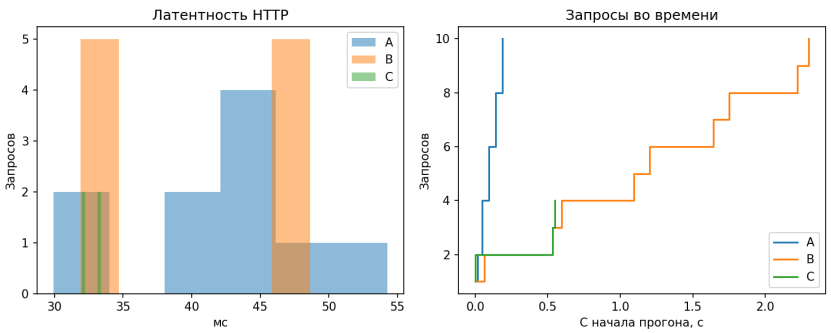
Watermark хранит версии ресурсов manifest. Неизменившиеся страницы не запрашиваются; для архива используются сохранённые записи.

8. Сравнение A/B/C

Показатель	A	B	C
Режим	Без ограничителя и повторов	Вежливый	Вежливый + оптимизация
Запросов	10	10	4
Записей в результате	60	60	60
Получено заново по сети	60	60	0
Время, с	0.253	2.432	0.659
Тела ответов, байт	17826	17826	0
Ошибки / повторы	0% / 0	0% / 0	0% / 0
HTTP 304	0	0	4
Коды ответов	200: 10	200: 10	304: 4
Доля 429/403	0%	0%	0%
Медиана / p95, мс	45.0 / 50.9	40.7 / 48.5	32.6 / 33.4
Отбраковано / breaker	0 / 0	0 / 0	0 / 0

A - только демонстрация антипаттерна на локальной площадке, 10 запросов при пределе 30. Цена вежливости B - A составила 2.179 с. В C сохранены те же 60 записей, но новых загрузок записей нет: обработаны четыре 304 и пропущены шесть неизменившихся страниц.

Латентность и запросы во времени по настоящим журналам



9. Наблюдаемость

Каждый JSON-объект журнала содержит ts, run_id, event, host, url, status, ms, attempt, bytes и error. Отчёт считает распределение кодов, ошибки, 429/403, повторы, медиану и p95, объём, 304, активации предохранителя, принятые и отвергнутые записи и длительность.

Порог	Граница красного	Причина
Ошибки	Более 20%	Массовый сбой делает результат неполным
429 / 403	Более 10%	Нужно снизить нагрузку или остановиться
p95	Более 2000 мс	Сервер отвечает заметно медленнее
Объём	Падение более 20% от медианы истории	Возможна смена страницы или неполный сбор
Размер ответа	Падение более 30%	Возможна заглушка; сравниваются тела записей, не robots/manifest
Заблокированные домены	Хотя бы один	Запрещено продолжать обход блокировки

A/B/C получили green. В faults было 12 запросов: 500 × 2, 200 × 5, 404 × 2, 429 × 3; ошибок 58,33%, доля 429/403 - 25%, повторов 5 и одна активация breaker. Сработали error_share > 20% и rate_or_block_share > 10%. При заглушке получены два HTTP 200, но blocked_domains=1 > 0, поэтому итог тоже red. Инцидентные прогоны получили red: сработали пороги ошибок либо блокировки. Для 304 и пропущенных страниц сравнение размера сетевого тела с историей не применяется, чтобы корректная экономия не выглядела деградацией.

10. Сопоставление с n8n

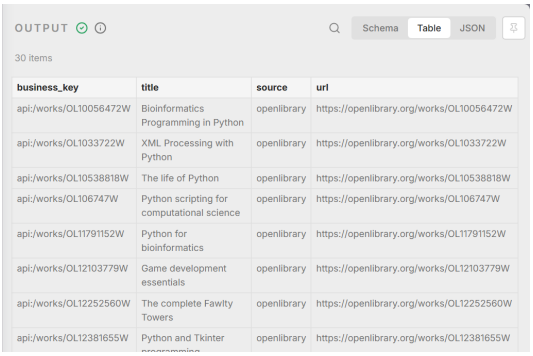
Механизм	Python	n8n	Что не реализовано в n8n
Скорость	Bucket по доменам, адаптация	Loop + Wait 0,6 с	Адаптация и отдельные лимиты доменов
Повторы	Full jitter, cap, бюджет	До трёх попыток, Retry-After	Full jitter и общий бюджет URL
4xx	Только 429 повторяется	Классификация; 404 один раз	Обновление токена не нужно источнику
Предохранитель	Три состояния, изоляция	Stop and Error	Нет восстановления half-open и изоляции
Условные запросы	ETag/Last-Modified, кэш	Не реализовано	Нет сохранения валидаторов и 304
Распределённый лимит	Владелец домена и блокировка	Не реализовано	Нет общего лимита экземпляров

11. Выполнение n8n и стоимость

На подмножестве API получены 30 строк за 2.166 с и три HTTP-запроса. Время взято из самого исполнения n8n, без импорта и опроса API. В 429-сценарии выполнены четыре запроса вместо трёх. При 404 выполнен один запрос, записан error_log.csv и вызван Stop and Error; бесконечного повтора нет.

Схема, JSON, CSV, проверка 429, проверка 404.

Успешный результат n8n: 30 строк



Для ежедневного сбора такого подмножества нужны 30 исполнений workflow и 90 обычных HTTP-запросов за 30 дней; ошибки могут добавить ограниченные повторы. Использована локальная Community-установка: плата платформе и API - 0. Электричество, ПК и сопровождение не оценивались. Облачный тариф не покупался. Настроено ежедневное расписание; для защиты используется ручной запуск.

12. Правовой чек-лист

Пункт	Результат
Источник и цель	Сохранённые HTML/REST-наборы работ 3 и 5; учебная проверка устойчивости.
Условия доступа	Учтены правила API. Наивный режим A выполняется только локально.
robots.txt	Quotes: 404, запрета нет. Open Library: Disallow: /search, can_fetch=false; URL пропущен. Crawl-delay для UA не задан; Sitemap сохранён.
Авторизация / обход	Для источников не нужны; обход защиты не применяется.
Частота	Стенд: 2 запроса/с, burst 1, jitter 25%; внешняя проверка: 0,9 запроса/с.
Данные и ПД	Книги, цитаты, имена авторов; имена могут быть ПД. Контакты не собираются.
Основание	Для учебной научной деятельности рассмотрен п. 8 ч. 1 ст. 6 152-ФЗ; права должны соблюдаться.
Хранение	Локально и в учебном репозитории; до 30 дней после проверки. Удаление включает кэши и версии.
Контакт в UA	Ссылка на aginGen/automated_data_collection.
Блокировка / претензия	Остановить домен, сохранить причину, проверить условия; удалить ненужное или запросить разрешённый доступ.

Полный чек-лист сохранён отдельно в legal_checklist.md. Применимость GDPR требует отдельной оценки территории и основания; публичность имени не равна согласию на любое использование.

Вывод: ограничитель добавляет время, зато ограничивает нагрузку и делает поведение при сбое проверяемым. Для неизменившихся ресурсов кэш и инкрементальность сокращают и число запросов, и размер передаваемых тел. При запрете или блокировке сбор прекращается.

Источники

- HTTP: RFC 9110, robots: RFC 9309.

- AWS Backoff and Jitter, Circuit Breaker.

- Open Library API, Quotes to Scrape.

- n8n HTTP Request, 152-ФЗ.