Лабораторная работа 7

Устойчивый и легальный пайплайн

Урбанович И. О. · ПМИ-2-2025 · Вариант 3 · 31 октября 2026 года

1. Цель, выбранный сборщик и вариант

Цель работы - сделать сборщик устойчивым к отказам, ограничить нагрузку на источники и проверить его работу по журналам.

HTML-часть основана на BooksSpider из архивной лабораторной 5 с Books to Scrape (automated_data_collection_old_labs_2026-10-27/lab5). Для смешанного профиля добавлен HTTP-клиент Open Library из лабораторной 3. Оба источника обслуживает один Collector. Вариант: номер в списке 26, (26 mod 6)+1=3. Обязательные отказы - 500 одного источника при доступности второго и 404 на части URL.

Сохранённый внешний срез от 27 октября: три HTML-страницы Books to Scrape (60 книг) и три JSON-карточки Works (3 книги). Поведение при отказах проверено на локальном HTTP-стенде. Дополнительно выполнена полная локальная серия A/B/C с одинаковыми 165 записями: 60 HTML + 105 API. Учебный Colab использован как основа для limiter, retry, breaker, detector и JSONL. Добавлены общий бюджет URL, блокировка владельца домена и персистентный курсор.

2. Аудит исходного кода

Проверка	Было в лабораторных 3 и 5	Сделано в лабораторной 7
Скорость	AutoThrottle, фиксированный интервал API	Token bucket по домену, EWMA и джиттер
robots.txt	Проверка Scrapy	robotparser для каждого собираемого пути
Повторы	Лимит попыток, Scrapy повторял 408	Классы ошибок, full jitter, Retry-After, 408 без повтора
Предохранитель	Отсутствовал	closed, open и half-open по домену
Сокращение нагрузки	Необязательный кэш Scrapy	ETag/Last-Modified, gzip, курсор изменений
Диагностика	Проверки полей и CSV-журнал API	Проверка тела, артефакты, JSONL, метрики и пороги

3. Расчёт лимитов и robots.txt

В B/C на внешний домен заданы 0,5 запроса/с, burst=1 и положительный джиттер до 25%. Базовый интервал 2-2,5 с выбран для трёх URL на домен: при исходной сетевой латентности около 0,4-0,8 с занятость последовательного соединения составляет примерно 20-40%. Между началами трёх запросов нужно не менее четырёх секунд. EWMA учитывает измеренную латентность, а 429/503 увеличивают задержку. Crawl-delay имеет приоритет, если он больше собственного интервала.

В сохранённых проверках Books robots.txt вернул 404: правил нет, условия сайта продолжают действовать. Open Library вернул 200: выбранные /works/...json разрешены, /search запрещён и исключён. Для используемых путей can_fetch=True, crawl_delay и request_rate не заданы. Sitemap Books отсутствует, Open Library - https://openlibrary.org/static/sitemaps/siteindex.xml.gz. Результаты: analysis.ipynb, раздел metadata.lab7_evidence.reports.

Четыре процесса не получают четыре отдельных квоты: межпроцессная блокировка допускает одного владельца домена, остальные отказываются от его обработки. В проверке из четырёх процессов один получил домен, три были отклонены. Решение рассчитано на одну файловую систему. Между машинами нужен общий счётчик или очередь.

4. Классификация ошибок и политика повторов

Код или исключение	Класс	Действие
200 / 304	Успех / без изменений	Проверить тело / восстановить проверенный кэш
429	Ограничение частоты	Снизить скорость, ждать Retry-After или backoff
5xx	Временный отказ сервера	Повтор в пределах бюджета, учёт в breaker
Сеть, таймаут	Временный транспортный отказ	Повтор в пределах бюджета
401	Ошибка авторизации	Без повтора, источник публичный, токенов нет
403	Возможная блокировка	Без повтора, остановить домен, сохранить инцидент
Прочие 4xx, в том числе 404/408	Постоянная ошибка клиента	Без повтора

Не более трёх попыток на URL. Full jitter выбирает задержку от 0 до min(4 с, 0,5 с × 2^(попытка-1)). Retry-After в секундах или HTTP-date имеет приоритет и не обрезается кэпом backoff. Если ожидание не помещается в общий бюджет, URL прекращает обрабатываться. В B/C бюджет 40 с включает ожидание limiter, повторы и передачу. HTTP-процесс завершается по дедлайну. Тест медленной передачи ограничил запрос бюджетом 1,5 с. Номер попытки, код, задержка и её источник записываются в JSONL.

5. Предохранитель и отказы варианта

После двух последовательных временных отказов домен переходит из closed в open. Запросы к нему пропускаются до окончания настраиваемой паузы, затем допускается одна проба half-open. Успешная проба возвращает closed. Новый временный отказ вновь открывает предохранитель.

В локальном сценарии получены два 500, запрос в open пропущен, второй источник вернул 200, затем проба первого завершилась 200. Отдельный URL с 404 запрошен ровно один раз. В отчёте сценария одна активация breaker, статус red, оповещения errors>10% и breaker>0. Искусственные отказы на внешних сайтах не воспроизводились.

6. Измеренная экономия нагрузки

Механизм и область измерения	Запросы до / после	Байты тела до / после	Экономия
ETag/Last-Modified, Books B→C	3 / 3	152720 / 0	100,00%
gzip, Works API B→C	3 / 3	1583 / 939	40,68%
Watermark, отдельный локальный feed B→C	1 / 1	17656 / 880	95,02%

Трафик - переданные байты тела до распаковки, без заголовков и TLS. Ответ 304 сокращает тело, но сохраняет HTTP-запрос. Валидаторы и проверенные записи хранятся между прогонами. Локальный feed сравнивает полный снимок из 105 записей с пятью изменениями и 100 сохранёнными записями: после объединения результат одинаков, курсор 105 прочитан новым Collector.

Наличие такого курсора у Open Library не предполагается. Для одновременной проверки трёх механизмов выполнена отдельная полная серия A/B/C на localhost: HTML дал 304, API вернул пять изменений в gzip, результат C совпал с полным снимком. Предварительное заполнение кэша вынесено за границы замеров повторного сбора и явно указано в блокноте. Экономия отдельных опытов не складывается.

7. Детектор блокировок и инциденты

Проверяются 403/429, маркеры captcha, access denied, «доступ ограничен», малое тело и отсутствие ожидаемых элементов при 200. Возможны ok, suspicion и blocked. Подозрительные данные отбрасываются. При blocked домен останавливается, тело и заголовки сохраняются в logs/incidents/, журнал получает событие инцидента, процесс возвращает ненулевой код. Синтетическая CAPTCHA с HTTP 200 дала exit code 1. В реальных ответах Books проверены article.product_pod, в JSON Works - обязательные ключи. Вердикты ok сохранены в журнале.

8. Отчёт о прогоне и оповещения

Показатели основной локальной серии A/B/C от 30 октября: reports/run_report_A.json, run_report_B.json и run_report_C.json. В каждом режиме одинаковые 165 записей. События request сверены с файлами отчётов по числу запросов, HTTP-кодам и байтам. Служебные события не считаются HTTP-попытками.

Показатель	A	B	C
Запросы к данным	6	6	6
Коды HTTP	200: 6	200: 6	304: 3, 200: 3
Доля ошибок, 429/403	0%, 0%	0%, 0%	0%, 0%
Повторы / активации breaker	0 / 0	0 / 0	0 / 0
Медиана / p95 HTTP, мс	336.5 / 359	398.5 / 484	367 / 390
Трафик тела HTTP, байт	23411	23411	343
Ответы 304	0	0	3
Принято / отброшено	165 / 0	165 / 0	165 / 0
Длительность, с	2.047	9.5	10.046
Статус, оповещения	green, нет	green, нет	green, нет

Функция summarize возвращает список оповещений и green/red. Любой сработавший порог даёт red. Порогам сопоставлены следующие причины.

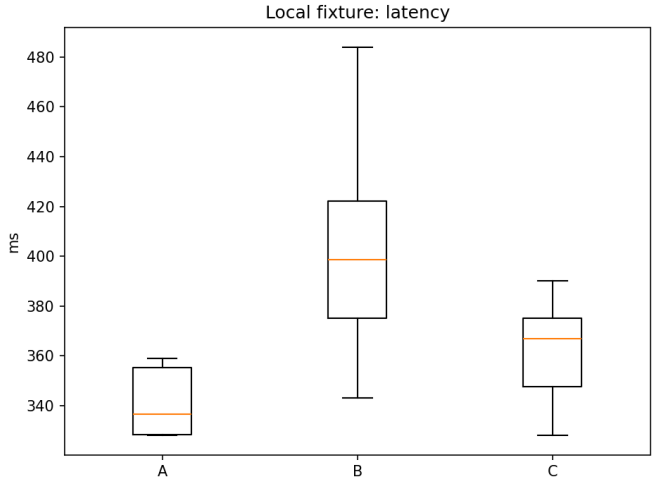
Порог	Почему применяется
Ошибки >10%	Больше одного отказа на десять попыток
403/429 >0%	Нужно сразу пересмотреть доступ или скорость
p95 >5000 мс	Карточка отвечает существенно медленнее обычного
Повторы >20%	Сбор создаёт много дополнительных запросов
Активации breaker >0	Есть устойчиво отказывающий источник
Принято 0 записей	Пустой сбор нельзя считать успешным
Записи ±20%, размер ±30% от медианы	Потеря записей или уменьшение сопоставимого ответа

История среднего размера ответа группируется по источникам, числу ресурсов и типу ответа full/incremental. Сравниваются распакованные тела, для 304 - сохранённые размеры. Первый C не имеет истории incremental и не сравнивается с полными ответами A/B. Дополнительно сравнивается нормализованный размер полного восстановленного набора на ресурс. Проверки с потерей записей, уменьшением полного набора и малым повторным incremental-ответом дали соответствующие оповещения. JSONL содержит поля ts, run_id, event, host, url, status, ms, attempt, bytes, error. Каждая строка - самостоятельный JSON-объект.

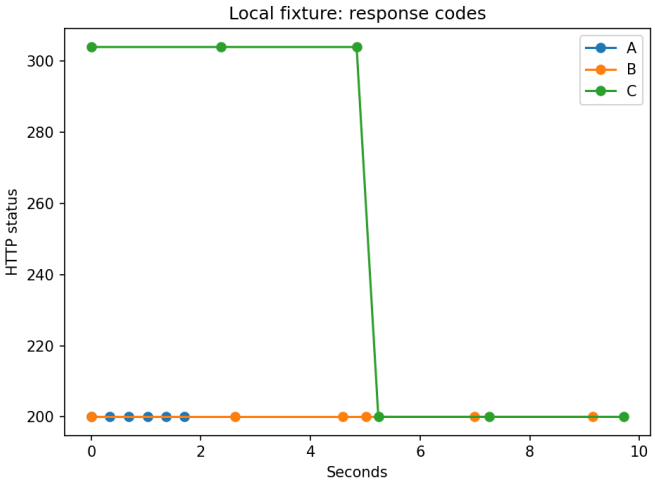
9. Сравнение A/B/C и графики

A отключает limiter, повторы и условные заголовки. B включает token bucket, адаптацию и повторы. C добавляет ETag/Last-Modified, gzip и сохранённый watermark. Все режимы используют одинаковый HTTP-транспорт с общим бюджетом URL. Основная серия выполнена на локальной тренировочной площадке, в A шесть запросов к данным. До C отдельно сохранены 60 HTML-записей и 100 API-записей. API затем содержит 105 записей. Это опыт повторного сбора, стоимость первоначальной загрузки не включена.

Полные данные A/B/C совпали после сериализации: 165 записей в каждом режиме. B-A = 7.453 с - измеренная цена вежливости этой серии. C передал на 98.53% меньше байтов тела, чем B. Три запроса на домен задействуют ожидание limiter. Во всех режимах в латентность входит запуск дочернего HTTP-процесса. Случайный джиттер и разовый замер ограничивают точность разницы времени.



Распределение латентности локальной серии по JSONL



Коды HTTP локальной серии во времени по JSONL

Внешние сохранённые замеры 27 октября вынесены отдельно: по шесть запросов и 63 записи. Время A 9.828 с, B 38.937 с, C 29.453 с. Тело B 154303 байта, C 939 байт. C получил три 304 и три 200 gzip. Внешний C не проверяет watermark, а A выполнен после B/C. Порядок, серверный кэш и сетевые задержки не контролировались. Поэтому делать из этих времён вывод об ускорении алгоритма нельзя. Внешние таблицы и два графика сохранены в analysis.ipynb и reports/comparison.md.

Небольшая выборка описывает только проведённые попытки: медиана и p95 не являются оценкой долгосрочной доступности источников.

10. Код и no-code, стоимость

Основной workflow повторно выполнен в n8n 31 октября: 60 книг с трёх страниц Books. Loop Over Items выдаёт по одному URL, Wait ждёт 1 с, Retry On Fail - до трёх попыток через 1500 мс при транспортном сбое. IF проверяет HTTP 200 и минимум 20 карточек. Ошибка сохраняется в CSV, затем Stop And Error завершает прогон. В этом же workflow есть ветка Error Trigger → Telegram Send Message, отдельный файл обработчика не нужен. Одно тестовое сообщение успешно отправлено в личный чат владельца через узел Telegram. Автоматическая связка Error Trigger проверена отдельно через временный webhook и локальный приёмник. Переносимый экспорт не содержит токена и Chat ID: при новом импорте подключение настраивается заново. Расписание 08:00 Asia/Yekaterinburg неактивно.

Механизм	Python	n8n и ограничения
Скорость	Token bucket, EWMA	Wait + batch=1, без адаптации
Повторы	Классы, backoff, Retry-After	Транспортные сбои, HTTP 403/404/5xx не повторяются
Предохранитель	closed/open/half-open	Состояние и проба не реализованы
Условные запросы	Сохранённые валидаторы	Не реализованы
Распределённый лимит	Один владелец домена на машине	Нет общего лимита
Результат и ошибка	Детектор, артефакты, exit code	IF, CSV, Stop And Error, Error Trigger → Telegram, учётные данные локально

Ежедневный сбор: 30 запусков и 90 HTTP-запросов за 30 дней без повторов, плюс один запуск обработчика и одно сообщение на каждый сбой. Self-hosted Community Edition: плата за лицензию для учебного личного использования 0. Инфраструктура отдельно. Проверки и подключение описаны в nocode/nocode_notes.md.

11. Правовой чек-лист

Пункт	Ответ
Источники и назначение	Books - учебный HTML-каталог, Open Library - метаданные Works, localhost - тесты
Цель и правомерность	Учебная проверка устойчивости, без текстов и обложек книг
Условия использования	Books - demo для scraping, API Open Library допускает учебные lookup-запросы с ограничением нагрузки
robots.txt	Books 404, Works can_fetch=True, Search исключён, Crawl-delay не задан
Авторизация	Не используется, только публичные ресурсы
Обход защиты	Нет, постоянный User-Agent, без прокси и решения капчи
Объём и частота	Внешний срез 63 записи, B/C 0,5 запроса/с, burst=1 на домен
Состав и ПДн	Набор: названия и ключи книг. Служебно в локальном n8n хранится Chat ID владельца для уведомлений
Основание при наличии ПДн	Chat ID предоставлен владельцем для уведомлений по его поручению, в экспорт не включён
Хранение и удаление	Локально и в учебном GitHub-репозитории. Срок копий до проверки +30 дней, затем ручное удаление
Контакт User-Agent	https://github.com/aginGen/automated_data_collection
Претензия или блокировка	Остановить домен, сохранить инцидент, разобрать условия и запрос на удаление

12. Выводы

Повторы ограничены временем и типом ошибки, отказ домена изолируется. Повторный сбор сохранил одинаковые данные при меньшем трафике. Полные правовые ответы - в legal_checklist.md.

13. Источники

Учебный Colab, Books, Open Library API, лицензирование, RFC 9110, RFC 9309, robotparser, AWS full jitter, Circuit Breaker, n8n Community, Error Trigger, Telegram credentials.